

משפטים והגדרות מודלים ב

עמית ירון

9 באפריל 2022

1 מבוא לסטטיסטיקה א-פרמטרית :

מוטיבציה :

אז בסטטיסטיקה א פרמטרית אנחנו עומדים פונקצית התפלגות ולא פרמטר בודד בגלל זה $\dim[\Theta] = \infty$ ישנם 3 בעיות מרכזיות בסטטיסטיקה

1. אמידה נקודתית של f

2. רווח סמך על f

3. בדיקת השערות f

מדדים ונורמות מוכרות :

1. $MSE(\hat{f}, f) = E_F[\hat{f} - f]^2 = var(\hat{f}) + [\hat{f} - E(\hat{f})]^2$ נקרא גם *Mean Squared Error*

(א) MSE הוא עבור נקודה קבועה x_0 ! או עבור וקטור קבוע \vec{x}_0

2. $\|\hat{f} - f\|_\infty = \lim_{n \rightarrow \infty} \sup_{x \in \mathbb{R}} |\hat{f}_n - f|$ התכנסות במידה שווה *uniform convergence* או *Mean Uniform Error*

(א) $x \in \mathbb{R}$ רצף של נקודות אמידה פונקציונלית

3. נורמת L^2 הינה $E_F[\int_{\mathbb{R}} (\hat{f} - f)^2 dF] = E_F[\int_{\mathbb{R}} (\hat{f} - f)^2 \cdot f_x dx]$ $\|\hat{f} - f\|_{L^2} =$

4. נורמת $MISE$ הינה : $MISE = E_F \int_{\mathbb{R}} (\hat{f} - f)^2 dx =$ ההבדל מנורמה L^2 היא שבאינטגרל יש dx ואין $dF(x)$! *MeanUniformError*

5. $\|\sqrt{n}(\hat{F}(X^k) - F(X^k))\|_{\Sigma_F} = \sqrt{n}(\hat{F}(X^k) - F(X^k))^T \cdot \Sigma_F^{-1/2} \cdot \Sigma_F^{-1/2} \cdot \sqrt{n}(\hat{F}(X^k) - F(X^k))$

6. ראה פרק 4 אצל פבל

1.0.1 טריקים חשובים שהופיעו במהלך הקורס

1. וקטור מקרי $\vec{X} = \begin{pmatrix} x_1 \\ \vdots \\ x_k \end{pmatrix}$ מתנהג מולטינומי כלומר $\vec{X} \sim multi(n, \begin{pmatrix} p_1 \\ \vdots \\ p_k \end{pmatrix})$ אם כל רכיב בוקטור מתנהג בינומי כלומר אם $x_i \sim Bin(n, p_i) \forall i \in$ מתרגיל 1 בשיעורי בית ! $[k]$

2. משפט הגבול המרכזי אם $X_1, \dots, X_n \stackrel{i.i.d}{\sim} f$ וגם $EX_1 < \infty, EX_1^2 < \infty$ אז במקרה שלנו $\bar{X} = \hat{F}_n(x_0)$! $\begin{cases} \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0, 1) \\ \Downarrow \\ \sqrt{n} \cdot (\bar{X} - \mu) \xrightarrow{d} N(0, \sigma^2) \end{cases}$

3. אם יש לנו ביטוי $\lim_{n \rightarrow \infty} E(Y_n)$ ונרצה להחליף אותו ב $E(\lim_{n \rightarrow \infty} Y_n)$

יש לנו קריטריון שאומר כי Y_n אינטגרלית במידה שווה \iff קיימת ϕ כך ש $\lim_{x \rightarrow \infty} \frac{\phi(x)}{x} = \infty$ $\begin{cases} \lim_{x \rightarrow \infty} \frac{\phi(x)}{x} = \infty \\ \sup_{n \in \mathbb{N}} E\phi(|Y_n|) < \infty \end{cases}$ מתרגיל 1 שאלה 7

4. נגזרת כיוונית מוגדרת להיות $\lim_{t \rightarrow 0} \frac{f(\vec{x} + t \frac{\vec{v}}{\|\vec{v}\|}) - f(\vec{x})}{t}$ כאשר אנו מחשבים את \vec{x} בכיוון \vec{v} בנוסף אם F היא דיפרנציאבילית $\nabla f, \vec{v} = \langle D_{\vec{v}} f, \vec{v} \rangle$ מויקיפדיה

5. $1_{\{X_j < b\}} - 1_{\{X_j < a\}} = 1_{\{a < X_j \leq b\}}$ שימו לב לא "ש החזק בצד שמאל !

$$\int_{\mathbb{R}} 1_{x \in [a,b]} dF = F(b) - F(a) \quad .6$$

$$\hat{\theta} = \left(\frac{\bar{X}}{S_n^2} \right) \text{ אם } X_1, \dots, X_n \stackrel{i.i.d}{\sim} N(\mu, \sigma^2) \text{ ואומדים את } \theta = \left(\frac{\mu}{\sigma^2} \right) \text{ בעזרת } MLE \text{ שזה יוצא}$$

$$\begin{cases} Var(\sqrt{n}\bar{X}) = \sigma^2 \\ Var(\sqrt{n}S_n^2) = 2\sigma^4 \end{cases} \text{ כי } \sqrt{n}[\hat{\theta} - \theta] \xrightarrow{d} N\left(0, \begin{pmatrix} \sigma^2 & 0 \\ 0 & 2\sigma^4 \end{pmatrix}\right) \text{ נקבל כי}$$

$$q(p) = \mu + \sqrt{\sigma^2} \cdot Z_p \text{ פבל } \textbf{שאלה 3 אצל פבל}$$

$$(x+y)^n = \binom{n}{0}x^n + \binom{n}{1}x^{n-1}y + \binom{n}{2}x^{n-2}y^2 + \dots + \binom{n}{n-1}x^1y^{n-1} + \binom{n}{n}y^n \quad .9$$

$$(x+y)^7 = x^7 + 7x^6y + 21x^5y^2 + 35x^4y^3 + 35x^3y^4 + 21x^2y^5 + 7xy^6 + y^7 \quad (\text{א})$$

$$(x+y)^6 = x^6 + 6x^5y + 15x^4y^2 + 20x^3y^3 + 15x^2y^4 + 6xy^5 + y^6 \quad (\text{ב})$$

$$(x+y)^5 = x^5 + 5x^4y + 10x^3y^2 + 10x^2y^3 + 5xy^4 + y^5 \quad (\text{ג})$$

$$(x+y)^4 = x^4 + 4x^3y + 6x^2y^2 + 4xy^3 + y^4 \quad (\text{ד})$$

$$(x+y)^3 = x^3 + 3x^2y + 3xy^2 + y^3 \quad (\text{ה})$$

.10 ממבחן מועד א של פבל:

$$E_F[F(\bar{X}_n)] = F(\bar{X}_n) = F(\overline{X_{n-1}}) \text{ לא ידועה } F \text{ ו } X_1, \dots, X_n \stackrel{i.i.d}{\sim} F \quad (\text{א})$$

1.0.2 אמידה נקודתית של f על סמך פונק ההתפלגות האמפירית

אנחנו מניחים כי f $X_1, \dots, X_n \stackrel{i.i.d}{\sim} f$ כאשר f היא לא ידועה אבל $c.d.f$ הפונק הצוברת שלה מקיימת את התכונות שידועות לנו מהסתברות:

1. פונק לא יורדת

2. $f: \mathbb{R} \rightarrow [0, 1]$

3. $\lim_{x \rightarrow \infty} F(x) = 1$

4. $\lim_{x \rightarrow -\infty} F(x) = 0$

הצעה לאומדן נקודתי של f הינה היסטוגרמה כלומר פונק ההתפלגות האמפירית $\hat{F}_n(x) = \frac{1}{n} \cdot \sum_{j=1}^n 1_{\{X_j \leq x\}}$

טענות בסיסיות לפונק ההתפלגות האמפירית :

1. מדובר באומדן חסר הטייה כלומר $E_F[\hat{F}_n(x)] = F(x) \quad \forall x \in \mathbb{R}$

2. לפי מדד MSE עבור $x \in \mathbb{R}$ נקודה קבועה נקבל כי

$$MSE(\hat{F}_n(x), F_n(x)) = E_F[\hat{F}_n(x) - F_n(x)]^2 = Var[\hat{F}_n(x)] + \underbrace{Bias(\hat{F}_n(x), F_n(x))}_{=0} = F(x)[1 - F(x)] \leq \frac{1}{n} \cdot \frac{1}{4}$$

$$n \cdot \hat{F}_n(x) \sim Bin(n, F(x)) \text{ חישוב מומנט שני של } E_F[\sqrt{n}[\hat{F}_n(x) - F_n(x)]]^2 = Var[n \cdot [\hat{F}_n(x) - F_n(x)]] = F(x)(1 - F(x)) \leq \frac{1}{4} \quad (\text{א})$$

$$Var(\hat{F}_n) = \frac{1}{n} F(x)[1 - F(x)] \text{ מהשיעורי בית} \quad (\text{ב})$$

$$F(x)(1 - F(x)) \leq F(x) + (1 - F(x)) = 1 \quad (\text{ג})$$

(ד)

$$\int_{\mathbb{R}} F(x)(1-F(x))dx = \int_{-\infty}^0 F(x)(1-F(x))dx + \int_0^{\infty} F(x)(1-F(x))dx \leq \int_{-\infty}^0 F(x)dx + \int_0^{\infty} (1-F(x))dx = EX^- + EX^+ = E|X|$$

מתרגיל 1

$$E_F[\|\sqrt{n}(F_n - F)\|_2^2] \leq E_F X^+ + E_F X^- = E_F |X| \quad (\text{ה})$$

$$\begin{cases} = E \int_{\mathbb{R}} (\hat{F}(x0) - F(x0))^2 dF \iff \hat{F}_n(x) \xrightarrow{L^2} F \\ \lim_{n \rightarrow \infty} Sup |\hat{F}(x0) - F(x0)| \longrightarrow 0 \iff \hat{F}_n(x) \xrightarrow{Uniform} F \\ \hat{F}_n(x) \xrightarrow{p} F \end{cases} \quad (\text{ו}) \text{ מסקנה רלוונטית היא ש}$$

LLM Rule

$$3. \text{ כאשר } F \text{ היא בדידה עם אטומים אז } \begin{cases} \{x_1, \dots, x_k\} \\ \{p_1, \dots, p_k\} \end{cases}$$

$$\hat{F}_n(x_j) = \frac{1}{n} \sum_{i=1}^n 1_{\{X_i=x_j\}} = \hat{p}_j \text{ כאשר } D_n = \max_{1 \leq j \leq k} |\hat{p}_j - p_j| \quad (א)$$

$$p = \begin{pmatrix} \hat{F}_n(x_1) \\ \vdots \\ \hat{F}_n(x_k) \end{pmatrix} \quad \text{ב) } \sqrt{n}[\hat{p} - p] \xrightarrow{d} N(0, \Sigma_p) = Y \text{ כאשר } \Sigma_p = \text{dig}(p) - p^T p \text{ לכן } \max_{1 \leq j \leq k} D_n \xrightarrow{d} \max Y \text{ בנוסף}$$

$$4. \text{ מקרה מעניין של פונקציונל לינארי} \quad \begin{cases} T(\hat{F}_n) = \int_{\mathbb{R}^d} \psi d[\hat{F}_n] = \frac{1}{n} \sum_{j=1}^n \psi(X_j) = \bar{\psi}_n \\ T(\hat{F}_n) = \int_a^b \psi d[\hat{F}_n] = \frac{1}{n} \sum_{j=1}^n \psi(X_j) \cdot 1_{\{a \leq \psi(x_i) \leq b\}} \\ \int_{\mathbb{R}} 1_{x \in [a,b]} d\hat{F}_n = \hat{F}_n(b) - \hat{F}_n(a) \end{cases}$$

$$\delta_a(x) = \begin{cases} 1 & x = a \\ 0 & x \neq a \end{cases} \text{ כאשר } \int_{\mathbb{R}^d} \psi \cdot \delta_a dx = \int_{\mathbb{R}^d} \psi d[\delta_a] = \psi(a) \text{ זה קורה מכיון ש}$$

$$5. \text{ אמידה של תוחלת שונות ואחוזון של } \hat{F}_n \quad \begin{cases} \mu_{\hat{F}_n} = \bar{X} \\ \sigma_{\hat{F}_n}^2 = S_n^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^2 \\ q_{\hat{F}_n}(p) = \inf\{x \in \mathbb{R} \mid \hat{F}_n(x) > p\} = X_{(\lceil np \rceil)} \end{cases} \text{ כאשר } t \text{ של המשוואה } \mathbb{P}(\hat{F}_n < t) = 1 - \alpha$$

$$6. \text{ משפט } Glivenko - Cantelli \quad \sup_{x \in \mathbb{R}} |\hat{F}_n - F| = \|\hat{F}_n - F\|_{\infty} \xrightarrow{\mathbb{P}/a.s} 0$$

$$7. \text{ אם אנו עושים מעבר מסטטיטיקה אפרמטרית לסטטיטיקה פרמטרית נשים לב כי } \hat{F}_n(x) = F(\hat{\lambda}_n, x) \text{ דוגמא :} \\ \text{שאלה 7 תרגיל 1 אם } X_1, \dots, X_n \stackrel{i.i.d}{\sim} Exp(\lambda) \text{ אז } E\|\hat{F}_n - F\|_{L_2}^2 = E_F \int_{\mathbb{R}} (e^{-\hat{\lambda}_n x} - e^{-\lambda x})^2 dF_X \text{ כאשר } \hat{\lambda} \text{ הוא לרוב אומד } M.L.E \text{ או אומד}$$

בשיטה כלשהי

$$8. \text{ נניח שאנו רוצים להראות ש} \lim_{n \rightarrow \infty} \sup_{F \in \mathcal{F}} E_F |\sqrt{n}(T(\hat{F}_n) - T(F))|^p = \infty \text{ עבור } p > 0 \\ \lim_{n \rightarrow \infty} \sup_{F \in \mathcal{F}} E_F |\sqrt{n}(T(\hat{F}_n) - T(F))|^p \geq \sqrt{n} \cdot a^p > 0 \text{ את הביטוי } \\ \text{כאשר } a^p \in \mathbb{R} \text{ קבוע כלשהו נשים לב כי } E_F |T(\hat{F}_n) - T(F)|^p \geq R^p \cdot \mathbb{P}(|T(\hat{F}) - R|) \\ \underbrace{|T(\hat{F}_n) - T(F)|^p}_{=R} \geq R^p \text{ ואז נחרטט ונגיע ל-} R^p$$

ואז הגענו לכך ש

$$\lim_{n \rightarrow \infty} \sup_{F \in \mathcal{F}} E_F |\sqrt{n}(T(\hat{F}_n) - T(F))|^p \geq \sqrt{n} \cdot a^p > 0$$

אשאיף את $a^p \sqrt{n} \rightarrow \infty$ ואקבל את הדרוש בשאלה ! מבוחן של פבל שנה שעברה

1.1 רווח סמך על סמך ההתפלגות האמפירית \hat{F}_n

1.1.1 רווח סמך אסימפטוטי על סמך פונק ההתפלגות האמפירית $\hat{F}_n(x_0)$ המקרה הבודד בנקודה קבועה x_0

לפי משפט הגבול המרכזי נקבל כי אם $X_1, \dots, X_n \stackrel{i.i.d}{\sim} f$ נקבל כי

$$\sqrt{n}(\hat{F}_n(x_0) - F(x_0)) \xrightarrow{d} N[0, F(x_0)(1 - F(x_0))] \quad \forall x_0 \in \mathbb{R}$$

על סמך טענה זו נבנה רצועת סמך

$$\hat{F}_n(x_0) - \frac{1}{\sqrt{n}} \cdot [F(x_0)(1 - F(x_0))] \cdot Z_{1-\alpha/2} < F(x_0) < \hat{F}_n(x_0) + \frac{1}{\sqrt{n}} \cdot [F(x_0)(1 - F(x_0))] \cdot Z_{1-\alpha/2} \quad \forall x_0$$

1.1.2 $\hat{F}(\vec{x}_0)$: נרצה לבנות רצונות סמך עבור המקרה ש $[F(x_1), F(x_1), ..F(x_n)]$ כאשר $x_1 < x_2 < ... < x_n$ המקרה הוקטורי

$$F(X^k) = \begin{pmatrix} F(x_1) \\ \vdots \\ F(x_k) \end{pmatrix}, F_n(X^k) = \begin{pmatrix} \hat{F}_n(x_1) \\ \vdots \\ \hat{F}_n(x_k) \end{pmatrix}, (X^k) = \begin{pmatrix} (x_1) \\ \vdots \\ (x_k) \end{pmatrix} \quad \text{תחילה נגדיר}$$

• מתקיים כי $Sup_{F \in \mathcal{F}} E_F ||\sqrt{n}(\hat{F}(X^k) - F(X^k))||_2 \leq C_k$ הקבוע C תלוי ב-

• לפי ה-CLT מתקיים כי $\sqrt{n}(\hat{F}(X^k) - F(X^k)) \xrightarrow{d} N(0, \Sigma_F)$

$$[\Sigma_F]_{i,j} = E_F 1_{\{X_1 \leq x_i\}} 1_{\{X_1 \leq x_j\}} - E_F 1_{\{X_1 \leq x_i\}} \cdot E_F 1_{\{X_1 \leq x_j\}} = \text{כאשר } \Sigma_F = Cov_F \left[\begin{pmatrix} 1_{\{x_1 < x\}} \\ \vdots \\ 1_{\{x_k < x\}} \end{pmatrix}, \begin{pmatrix} 1_{\{x_1 < x\}} \\ \vdots \\ 1_{\{x_k < x\}} \end{pmatrix} \right] \text{ כאשר נגדיר את } F(x_i \wedge x_j) - F(x_i)F(x_j)$$

$$\|\sqrt{n}(\hat{F}(X^k) - F(X^k))\|_{\Sigma_F} = \sqrt{n}(\hat{F}(X^k) - F(X^k))^T \cdot \Sigma_F^{-1/2} \cdot \Sigma_F^{-1/2} \cdot \sqrt{n}(\hat{F}(X^k) - F(X^k)) \xrightarrow{d} \chi_{k,1-\alpha}^2 \text{ נשים לב כי}$$

נקבל מכל הטענות אלו קבוצת סמך שהיא בצורת אלפסויד

$$E_\alpha(X^n) = \{v \in \mathbb{R}^k \mid \|\hat{F}(X^k) - v\|_{\Sigma_F} \leq \frac{1}{n} \chi_{k,1-\alpha}^2\}$$

כלומר $\mathbb{P}[F(X^k) \in E_\alpha] \longrightarrow \psi[\chi_{k,1-\alpha}^2]$ של הצוברת של χ^2 !

1.1.3 רווח סמך עבור המקרה הרציף של פונק ההתפלגות האמפירית לפי התפלגות קולמוגורוב ולפי משפט (DKW) כלומר עבור $F(x)$ כל הנקודות ב \mathbb{R}

מוטיבציה : על מנת לבנות את הרווח הסמך עבור המקרה הרציף נצטרף להעזר במספר טענות חשובות

1. אומד \hat{F}_n הוא עקיב ל F אם מתקיים כי $\rho(\hat{F}_n, F) \xrightarrow{p} 0$ כאשר ρ היא מטריקה במרחב הפונקציות \mathcal{F} לרוב $\rho = \|\cdot\|_\infty$ בדרך כלל הכוונה היא ש $T(\hat{F}_n) \xrightarrow{p} T(F)$ משיעורי בית של פבל !

2. **טענה חשובה :** משפט *Glivenko - Cantelli* מתקיים כי $\sup_{x \in \mathbb{R}} |\hat{F}_n - F| = \|\hat{F}_n - F\|_\infty \xrightarrow{\mathbb{P}/a.s} 0$

$$D_n \stackrel{def}{=} \sqrt{n} \cdot \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| = \sqrt{n} \cdot \|\hat{F}_n(x) - F(x)\|_\infty$$

טענות חשובות על המשתנה

• D_n הוא לא סטטיסטי מכיון שההתפלגות שלו תלויה ב F ! כאשר F רציפה ההתפלגות שלו לא תלויה ב F

– ראה תרגיל 1 כאשר F היא פונק אטומית עם

- טענה חשובה: D_n הוא פיבוט כלומר ההתפלגות שלו לא תלויה ב F רק כאשר F רציפה !!

• יהי $X_1, \dots, X_n \stackrel{i.i.d}{\sim} F$ כאשר F רציפה (*) אזי מתקיים כי $F(X_j) = V_j \sim U(0, 1)$

– מדוע D_n הוא פיבונט כאשר F רציפה:

$$\sqrt{n} \cdot \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| = \sqrt{n} \cdot \sup_{x \in \mathbb{R}} \left| \frac{1}{n} \sum_{i=1}^n 1_{\{X_j \leq x\}} - F(x) \right| = \sqrt{n} \cdot \sup_{x \in \mathbb{R}} \left| \frac{1}{n} \sum_{i=1}^n 1_{\{F(X_j) \leq F(x)\}} - F(x) \right| = \sqrt{n} \cdot \sup_{x \in \mathbb{R}} \left| \frac{1}{n} \sum_{i=1}^n 1_{\{(V_j \leq u)\}} - u \right|$$

$$\mathbb{P}[F(X) \leq x] \stackrel{*}{=} \mathbb{P}[X \leq F^{-1}(x)] = \int_{-\infty}^{F^{-1}(x)} f_x dx = F[F^{-1}(x)] - F[-\infty] = FF^{-1}(x) = x : \text{אינטואיציה שקרית} -$$

– הוכחה פורמלית: $\mathbb{P}[F(X) \leq t] = E[1_{\{F(X) \leq t\}}] \stackrel{*}{=} \int_{\mathbb{R}} 1_{\{F(X) \leq t\}} \cdot f_X dx = \int_0^1 1_{\{u \leq t\}} \cdot du = u = F(X)$

• נניח כי F רציפה אזי מתקיים כי : $\sum_{j=-\infty}^{\infty} (-1)^j \cdot e^{-2j^2t^2} \xrightarrow{n \rightarrow \infty} \mathbb{P}(D_n \leq t)$ כאשר $\sum_{j=-\infty}^{\infty} (-1)^j \cdot e^{-2j^2t^2}$ היא התפלגות קולמוגורוב.

רצועת סמך קולמוגקרוב אסימפטוטית :

$$\underbrace{\mathbb{P}[\hat{F}_n(x) - \frac{1}{\sqrt{n}} \cdot K_{1-\alpha} \leq F(x)]}_{L_n(x)} \leq F(x) \leq \underbrace{\hat{F}_n(x) + \frac{1}{\sqrt{n}} \cdot K_{1-\alpha}}_{U_n(x)} = 1 - \alpha$$

כאשר $K_{1-\alpha}$ זה אחוזון $1 - \alpha$ של התפלגות קולמוגרוב

– כלומר $D_n \xrightarrow{d} K_{1-\alpha}$ כאשר $1 - \alpha$ זה התפלגות קולמוגורוב

• מכיון שקשה לחשב את אחוזון של התפלגות קולמוגורוב נעזרים בטענה הבאה **משפט (DKW) מתקיים** כי $\mathbb{P}_F[\sup_{x \in \mathbb{R}} |\hat{F}_n - F| \geq \varepsilon] \leq 2e^{-2n\varepsilon^2}$

– בעזרתו בונים רווח סמך מבלי להתבסס עם אחוזון קולמוגורוב מגדירים את $\varepsilon = \frac{c}{\sqrt{n}}$ ואז נקבל $\mathbb{P}_F[D_n \geq c] \leq 2e^{-2c^2}$

$$\mathbb{P}_F(D_n \leq c) \geq 1 - 2e^{-2c^2} = 1 - \alpha$$

* **רווח סמך על סמך משפט DKW** : נגדיר את $1 - \alpha = 1 - 2e^{-2c^2}$ ונקבל את רווח הסמך

$$\hat{F}_n(x) - \frac{1}{\sqrt{n}} \cdot c_\alpha \leq F(x) \leq \hat{F}_n(x) + \frac{1}{\sqrt{n}} \cdot c_\alpha$$

$$\text{כאשר } c_\alpha = \sqrt{\frac{1}{2} \log\left(\frac{\alpha}{2}\right)} \text{ שיעור 4}$$

• אם נשאל את השאלה האם ניתן למצוא אומד \tilde{F} ל F שמתכנס בקצב מהיר יותר מ \sqrt{n} אז התשובה היא **שלא**

– **טענה** : $\liminf_n \inf_{\tilde{F} \in \mathcal{F}_X} \sup_{F \in \mathcal{F}} E_F \|\sqrt{n}(\tilde{F} - F)\|_\infty \stackrel{Claim}{=} \liminf_n \inf_{F \in \mathcal{F}} \sup_{F \in \mathcal{F}} E_F \|\sqrt{n}(\hat{F}_n - F)\|_\infty$ כלומר במונחי \hat{F}_n הוא אומד האופטימלי!

• $D_n \stackrel{claim}{=} \sqrt{n} \max_{j \leq n} (|\frac{j}{n} - F(x_j)| \vee |\frac{j-1}{n} - F(x_j)|)$ מתרגיל 1 בשיעורי בית ! נועד כדי בפועל לחשב את D_n

הקטע הזה לא לבחינה

הוכחה של התפלגות קולמוגורוב יכולה להתבסס על משהו שנקרא תהליך מקרי (*Random process*) : ראה רישומים של פבל שבוע 1

נגדיר תהליך סטוכסטי $\bar{B}_n(x) = \sqrt{n}(\hat{F}_n(x) - x)$, $x \in [0, 1]$

1. **תאוריית דונסקר (Donsker)** : $[\sqrt{n}(\hat{F}_n(x) - F(x)), x \in \mathbb{R}] \xrightarrow{w} [\bar{B}(F(x)), x \in \mathbb{R}]$

$$E_F[\psi(\bar{B}_n)] = \int_{f \in \mathcal{G}} \psi(f) \mu_n df \longrightarrow \int_{f \in \mathcal{G}} \psi(f) \mu df \text{ כאשר ההתכנסות כאן מוגדרת}$$

i. כאשר $\psi : \mathcal{G} \rightarrow \mathbb{R}$ הוא פונקציונל רציף וחסום \mathcal{G} הוא מרחב כל הפונקציות.

הקטע הזה לא לבחינה

2 אמידה של פונקציונלים

הגדרה פונקציונלים : $T : \mathcal{F} \rightarrow \mathbb{R}^k$ $k = 1$ ו \mathcal{F} מרחב פונק התפלגות מצטברת. סוגים שונים של פונקציונלים :

1. **פונקציונל לינארי** : $T(F) = \int_{\mathbb{R}} \psi(x) dF(x)$

(א) נשים לב כי מדובר בפונקציונל לינארית מכיון ש $T(F + G) = \int_{\mathbb{R}} \psi(x) d(F + G)(x) = \int_{\mathbb{R}} \psi(x) dF(x) + \int_{\mathbb{R}} \psi(x) dG(x) = T(F) + T(G)$

$$(b) \text{ מקרה מעניין של פונקציונל לינארי } \begin{cases} T(\hat{F}_n) = \int_{\mathbb{R}^d} \psi d[\hat{F}_n] = \frac{1}{n} \sum_{j=1}^n \psi(X_j) = \bar{\psi}_n \\ T(\hat{F}_n) = \int_a^b \psi d[\hat{F}_n] = \frac{1}{n} \sum_{j=1}^n \psi(X_j) 1_{\{a \leq x_j \leq b\}} \\ V_{\hat{F}_n} = \int (\psi - \bar{\psi})^2 d\hat{F}_n = \int \psi^2 d\hat{F}_n - (\bar{\psi})^2 \end{cases}$$

$$\delta_a(x) = \begin{cases} 1 & x = a \\ 0 & x \neq a \end{cases} \text{ כאשר } \int_{\mathbb{R}^d} \psi \cdot \delta_a dx = \int_{\mathbb{R}^d} \psi d[\delta_a] = \psi(a) \text{ זה קורה מכיון ש}$$

i. נשים לב שאם $T(\hat{F}_n) = \int_b^a \psi d[\hat{F}_n] = \frac{1}{n} \sum_{i=1}^n 1_{\{a \leq X_i \leq b\}}$ מסקנה מהבחון לדוגמא של פבל

$$ii. \int_b^a x d\Delta_X = x \cdot 1_{\{x \in (a, b]\}} \text{ מסקנה מהבחון לדוגמא של פבל !}$$

(ג) נניח כי $0 \xrightarrow{t \rightarrow 0} \|G_t - G\|_\infty$ וגם ψ פונקציה חסומה כלומר ולכל $\delta > 0$ קיימת ψ_δ כך ש $\|\psi - \psi_\delta\|_\infty < \delta$ אזי מתקיים כי $\int \psi dG_t \xrightarrow{t \rightarrow 0}$

$\int \psi dG$ מתרגול פבל

i. **מסקנה** : אם ψ פונק חסומה אזי $\dot{T}(G - F) = \lim_{t \rightarrow 0} \int \psi d(G_t - F) = \int \psi d(G - F)$ מתרגול פבל

ii. אם ψ לא חסומה לא בהכרח קיימת נגזרת הדמר !

iii. ראה תרגיל 2 שאלה 5 יש שם גם דוגמא נגדית מעולה ! נקח

$$\int \psi dG_\varepsilon = \frac{1}{\varepsilon^2} \cdot \varepsilon \xrightarrow{\varepsilon \rightarrow 0} \infty \text{ ואז נקבל כי } \begin{cases} \psi(x) = x^2 \\ G_\varepsilon = \begin{cases} \varepsilon & x = \frac{1}{\varepsilon} \\ 0 & \text{otherwise} \end{cases} \end{cases}$$

2. פונקציונל לא לינארי $T(F) = h[T_1(F), T_2(F), \dots, T_m(F)]$

(א) עבור $h : \mathbb{R}^m \rightarrow \mathbb{R}$ כאשר $T_j(F)$ הוא פונקציונל לינארי

(ב) דוגמא $T_j = \int_{\mathbb{R}} x^j dF(x)$ כאשר $T_2(F) - T_1(F)^2 = E[X^2] - E[X]^2 = \sigma^2(F)$

(ג) דוגמא אם $T(F) = \int_{\mathbb{R}} (F(x) - x)^2 dx$

$$T(\hat{F}_n) = \int (\hat{F}_n(x) - x)^2 dx = \sum_{j=1}^n \int_{X_{(j)}}^{X_{(j+1)}} \left(\frac{j}{n} - x\right)^2 dx = \sum_{j=1}^n \left[\left(\frac{j}{n}\right)^2 (X_{(j+1)} - X_{(j)}) - \left(\frac{j}{n}\right) (X_{(j+1)}^2 - X_{(j)}^2) + \frac{1}{3} X_{(j+1)}^3 - X_{(j)}^3 \right]$$

אז מתקיים כי

שאלה 8 תרגיל 2 אצל פבל

3. פונקציונלים לא לינאריים סמויים : מוגדרים להיות הפתרון של המשוואה $\int_{\mathbb{R}} h(x, t) dF(x) = 0$ עבור $h : \mathbb{R}^2 \rightarrow \mathbb{R}$

(א) דוגמא $q_F(p)$ עבור F רציפה מתקיים כי $\int_{\mathbb{R}} 1_{\{x \leq t\}} - p dt = 0 \iff F(t) = p$

2.1 שיטת הדלתא הפרמטרית עבור מקרה חד מימדי ועבור מקרה רב מימדי

הערה :

נשים לב מכיון ש $ImT \subset \mathbb{R}$ נדבר על רווחי סמך ולא על רצועות סמך

תזכורת על רווחי סמך בשיטת הדלתא המקרה החד מימדי והמקרה הרב מימדי :

• מקרה חד מימדי :

– נניח כי $\hat{\theta}$ אומד ל θ כך ש $\sqrt{n}[\hat{\theta} - \theta] \xrightarrow{d} N(0, V(\theta))$ כאשר $V(\theta)$ ידועה ותהי $g : \Theta \rightarrow \mathbb{R}$ כך ש g גזירה ו $\theta \in \Theta$ אזי מתקיים כי $\sqrt{n}[g(\hat{\theta}) - g(\theta)] \xrightarrow{d} N(0, V(\hat{\theta}) \cdot |g'(\theta)|^2)$ – לכן הרווח סמך יהיה

$$g(\hat{\theta}) - \frac{1}{\sqrt{n}} \cdot \sqrt{V(\hat{\theta}) \cdot |g'(\hat{\theta})|^2} \cdot Z_{1-\frac{\alpha}{2}} \leq g(\theta) \leq g(\hat{\theta}) + \frac{1}{\sqrt{n}} \cdot \sqrt{V(\hat{\theta}) \cdot |g'(\hat{\theta})|^2} \cdot Z_{1-\frac{\alpha}{2}}$$

– אם V לא ידועה אומדים אותה כלומר מכניסים את האומד $\hat{\theta}$ לשונות !

• מקרה רב מימדי :

– נניח כי $\hat{\theta}$ אומד ל $\vec{\theta}$ כך ש $\sqrt{n}[\hat{\theta} - \vec{\theta}] \xrightarrow{d} N(0, \Sigma)$ כאשר Σ ידועה ותהי $g : \Theta \rightarrow \mathbb{R}$ כך ש g גזירה ו $\vec{\theta} \in \Theta$ אזי מתקיים כי

$$\sqrt{n}[g(\hat{\theta}) - g(\vec{\theta})] \xrightarrow{d} N(\vec{0}, (\nabla g)^T \cdot \Sigma \cdot (\nabla g))$$

– אם $g : \Theta \rightarrow \mathbb{R}^m$ כך ש $k = \text{Range}(\Theta) \leq \text{Range}(g) = m$ אז תחת אותם תנאים בדיוק נקבל כי $\sqrt{n}[g(\hat{\theta}) - g(\vec{\theta})] \xrightarrow{d} N(\vec{0}, (Jg)^T \cdot \Sigma \cdot (Jg))$

$$J(g) = \begin{pmatrix} | & & | \\ \nabla f_1 & \dots & \nabla f_m \\ | & & | \end{pmatrix}$$

* כאשר $J(g)$ היא מטריצת יעקובאן

* רווח סמך במקרה הרב מימדי הינו

$$g(\hat{\theta}) \pm \frac{1}{\sqrt{n}} \sqrt{\nabla g(\hat{\theta}) \cdot \sum (\hat{\theta}) \cdot [\nabla g(\hat{\theta})]^T \cdot Z_{1-\frac{\alpha}{2}}}$$

ראה דוגמא בתרגיל 2 שאלה 3

2.2 שיטת הדלתא עבור המקרה הלא פרמטרי ופונקציית רגישות:

שיטת הדלתא המקרה הלא פרמטרי !! נרצה לבצע משהו דומה למה שביצענו במקרה הפרמטרי :
טענה שיטת הדלתא במקרה הלא פרמטרי :

$$\sqrt{n}[T(\hat{F}_n) - T(F)] \stackrel{*}{=} \dot{T}_F(\sqrt{n}[T(\hat{F}_n) - T(F)]) \cdot (1 + o(1)) \stackrel{def}{=} \sqrt{n} \int_{\mathbb{R}} \psi d[(\hat{F}_n - F)(1 + o(1))] = \sqrt{n} \left[\frac{1}{n} \sum_{i=1}^n \psi - E_F \right] \xrightarrow{d} N(0, V_F)$$

$$\dot{T}_F(\sqrt{n}[T(\hat{F}_n) - T(F)]) \cdot (1 + o(1)) \stackrel{def}{=} \sqrt{n} \int_{\mathbb{R}} \psi d[(\hat{F}_n - F)(1 + o(1))] \quad \bullet \text{ נדרוש כי}$$

$$\int_{\mathbb{R}} (\psi - E_{\hat{F}_n}(\psi))^2 d[F_n] = V_{F_n} \longrightarrow V_F = \int_{\mathbb{R}} (\psi - E_F(\psi))^2 d[F] \quad \bullet \text{ נדרוש כי}$$

$$V_{\hat{F}_n} = \int_{\mathbb{R}} [\psi(x) - T(\hat{F}_n)]^2 d\hat{F}_n = \frac{1}{n} \sum_{i=1}^n \psi^2(x_i) - [\bar{\psi}]^2 \xrightarrow{p} V_F \text{ אם } T(F) = E_F(\psi) \text{ אז נקבל כי}$$

• הטענה שמוצגת כאן היא כללית הן עבור פונקציונל לינארי והן עבור פונקציונל לא לינארי עבור כל מקרה בנפרד שיטת הדלתא מתנהגת קצת שונה.

• נקבל את הרווח סמך הבא

$$T(\hat{F}_n) \pm \frac{1}{\sqrt{n}} \cdot Z_{1-\frac{\alpha}{2}} \sqrt{V(\hat{F}_n)}$$

$$\begin{cases} V_{F_n} \longrightarrow V_F \\ V_{F_n} = \int_{\mathbb{R}} (\psi - E_{\hat{F}_n}(\psi))^2 d[F_n] \end{cases} \quad \text{כאשר}$$

$$\begin{cases} V(\hat{F}_n) = \int_{\mathbb{R}} L_{\hat{F}_n}(x)^2 d[\hat{F}_n] \\ L_F(x) = \dot{T}(\Delta_X - F) \end{cases} \quad \bullet \text{ כאשר הרבה פעמים כדי לחשב את } V(\hat{F}_n) \text{ נחשב את פונקציית הרגישות שהיא}$$

$$\dot{T}(G_\varepsilon - F) \quad \bullet \text{ קודם נחשב את}$$

$$G_\varepsilon = \Delta_X \quad \bullet \text{ לאחר מכן נציב בחישוב במקום}$$

$$G_\varepsilon = \Delta_X \quad \bullet \text{ נחשב את } V_F \text{ עם ההצבה של}$$

$$\quad \bullet \text{ לבסוף נחליף את } \hat{F} \text{ בחישוב}$$

$$\sqrt{n}[T(\hat{F}_n) - T(F)] \stackrel{*}{=} \text{שימו לב שברוח סמך אני משתמש באומד לשונות וביטוי הדלתא הביטוי} \quad \bullet$$

$$V_F \text{ מתכנס להתפלגות נורמלית עם שונות שהיא כן ידוע}$$

הגדרה 2.1 פונקציית רגישות: $L_F(x) = \dot{T}(\Delta_X - F)$ כאשר $\Delta_X = 1_{\{u \geq x\}}$ **המטרה של פונקציית הרגישות היא בחישוב השונות בשיטת דלתא לפי שניתן לראות בטענה השניה !**

$$L_F(x) = \dot{T}(\Delta_X - F) = \int_{\mathbb{R}} \psi d[\Delta_X - F] = \psi - E_F(\psi) \quad \bullet \text{ פונקציית רגישות עבור פונקציונל לינארי}$$

$$V_F = \int_{\mathbb{R}} (\psi - E_F(\psi))^2 d[F] = \int_{\mathbb{R}} L_F(x)^2 d[F] \quad \bullet \text{ מסקנה עבור פונקציונלים לינאריים :}$$

$$T(F) = \int_{\mathbb{R}} \psi dF \quad \bullet \text{ שיטת הדלתא עבור פונקציונלים לינאריים : כלומר עבור}$$

נגדיר נגזרת גאטו מדובר בנגזרת חלקית עבור פונקציות :

$$\dot{T}_F(F - G) = \lim_{t \rightarrow 0} \frac{T[(1-t)F + tG] - T(F)}{t} = \lim_{t \rightarrow 0} \frac{T[(F + t(G - F))] - T(F)}{t}$$

הגדרה פורמלית של נגזרת גאטו :

תהיי $T : (D, \|\cdot\|_\infty) \longrightarrow (E, \|\cdot\|_\infty)$ כאשר D מרחב של הפרש פונק התפלגות עם השתנות סופית ו E מרחב פונקציות התפלגות עם השתנות סופית. נאמר כי T היא גזירה בנקודה $F \in D$ בכיוון $G - F$ אם מתקיים כי $\dot{T}_F(F - G) = \lim_{t \rightarrow 0} \frac{T[(F + t(G - F))] - T(F)}{t}$

$$\dot{T}_F(F - G) = \int_{\mathbb{R}} \psi d[F - G] \quad \bullet \text{ במקרה של פונקציונל לינארי נקבל כי}$$

ואז לפי שיטת הדלתא במקרה של פונקציונל לינארי נקבל כי $\sqrt{n}[T(\hat{F}_n) - T(F)] = \dot{T}_F[\hat{F}_n - F] = \int_{\mathbb{R}} \psi d[\sqrt{n}(\hat{F}_n - F)] = \sqrt{n}[\bar{\psi} - E_F(\psi)] \xrightarrow{CLT} N(0, V_F)$

טענות בסיסיות על נגזרת הדמר ופונקציונלים לינאריים:

1. נניח כי $\|G_t - G\|_{\infty} \xrightarrow{t \rightarrow 0} 0$ וגם ψ פונקציה חסומה כלומר ולכל $\delta > 0$ קיימת ψ_{δ} כך ש $\|\psi - \psi_{\delta}\|_{\infty} < \delta$ אזי מתקיים כי $\int \psi dG_t \xrightarrow{t \rightarrow 0} \int \psi dG$ מתרגול פבל

(א) מסקנה: אם ψ פונק חסומה אזי $\dot{T}(G - F) = \lim_{t \rightarrow 0} \int \psi d(G_t - F) = \int \psi d(G - F)$ מתרגול פבל ! ומתרגיל 2 שאלה 5 !

(ב) אם ψ לא חסומה לא בהכרח קיימת נגזרת הדמר ! ראה דוגמא נגדית מתרגול פבל מספיק לבדוק עבור $\begin{cases} \psi(x) = x \\ G_t = (1-t)G + t\Delta_X \end{cases}$

(ג) דוגמא לפונק שהיא לא גזירה הדמר אבל גזירה גאטו: ראה תרגיל 2 שאלה 5 יש שם גם דוגמא נגדית מעולה ! נקח $\begin{cases} \psi(x) = x^2 \\ G_{\varepsilon} = \begin{cases} \varepsilon & x = \frac{1}{\varepsilon} \\ 0 & \text{otherwise} \end{cases} \end{cases}$

ואז נקבל כי $\int \psi dG_{\varepsilon} = (\frac{1}{\varepsilon})^2 \cdot \varepsilon \xrightarrow{\varepsilon \rightarrow 0} \infty$

2.2.2 שיטת דלתא עבור פונקציונלים לא לינאריים:

כאן נצטרך להגדיר נגזרת הדמר שהיא דומה לגאטו מאוד:

תהי $T : (D, \|\cdot\|_{\infty}) \rightarrow (E, \|\cdot\|_{\infty})$

• כאשר D מרחב של הפרש פונק התפלגות עם השתנות סופית ו E מרחב פונקציות התפלגיות עם השתנות סופית.

• המטרה של נגזרת הדמר היא לחשב את פונקציית הרגישות בקלות ואותה צריך בשביל לחשב את השונות לשיטת הדלתא ! מסקנות מהשיעורי בית !

– זו הסיבה שדורשים $\|G_{\varepsilon} - G\|_{\infty} \xrightarrow{t \rightarrow 0} 0$ שהרי $\|\hat{F}_n - F\|_{\infty} \xrightarrow{n \rightarrow \infty} 0$ ונצטרך זאת כאשר נשתמש בשיטת הדלתא ! מסקנות משיעורי בית

נאמר כי T היא גזירה אדמר בנקודה $F \in D$ בכיוון G_t לכל G_t שמקיים כי $\|G_{\varepsilon} - G\|_{\infty} \rightarrow 0$ אם מתקיים כי

$$\dot{T}_F(F - G_{\varepsilon}) = \lim_{\varepsilon \rightarrow 0} \frac{T[(1-\varepsilon)F + \varepsilon G_{\varepsilon}] - T(F)}{\varepsilon} = \lim_{\varepsilon \rightarrow 0} \frac{T[(F + \varepsilon(G_{\varepsilon} - F))] - T(F)}{\varepsilon}$$

נשים לב שזה שקול ל

$$\left\| \frac{T[(F + t(G_{\varepsilon} - F))] - T(F)}{\varepsilon} - \dot{T}(F - G) \right\|_{\infty} \rightarrow 0$$

• חובה לבדוק בנגזרת הדמר כי $\|G_t - G\|_{\infty} \rightarrow 0$!! זה ממש קריטי !

– ראה דוגמא בבוחן של פבל !

• אז לפי לשיטת הדגלתא במקרה של פונקציונל לא לינארי נקבל כי: $\sqrt{n}[T(\hat{F}_n) - T(F)] \xrightarrow{d} \dot{T}_F[\bar{B} \circ F] \sim N(0, V_F)$

– כאשר גם כאן $V_F = \int_{\mathbb{R}} L_F(x)^2 d[F]$

• נגזרת הדמר של אחוזון כלומר של הפונקציונל של $F^{-1}(q) = q_p(F) = \min\{x \in \mathbb{R} \mid F(x) \geq p\}$ הינה $\frac{F(q) - G(q)}{f(q)}$ $\dot{T}(G - F) = \lim_{t \rightarrow \infty} \frac{q_t - q}{t} = \frac{F(q) - G(q)}{f(q)}$

– באחוזון הגדרנו את האחוזון q_t להיות $p = (1-t)F(q_t) + tG_t(q_t)$ כאשר נדרוש כי $\begin{cases} G_t \text{ continuous} \\ \|G_t - G\|_{\infty} \\ F \text{ continuous} \end{cases}$

– מתקיים כי $q_t \rightarrow q$ מוכיחים טענה זו !

– עבור אחוזון האומד שנקבל הינו: $T(\hat{F}_n) = \min\{x \in \mathbb{R} \mid \sum_{i=1}^n 1_{\{X_i < x\}} > pn\} = X_{(\lceil np \rceil)}$

– רווח סמך של אחוזון תחת הדרישות לעיל הינו

$$X_{(\lceil np \rceil)} \pm \frac{1}{\sqrt{n}} \sqrt{p(1-p)} \cdot \frac{1}{\hat{f}_n(X_{(\lceil np \rceil)})} \cdot Z_{1-\frac{\alpha}{2}}$$

כאשר $V_F = \frac{p(1-p)}{[\hat{f}_n(X_{(\lceil np \rceil)})]^2} = \frac{F(q)[1-F(q)]}{[F'(q)]^2}$ מתרגול פבל.

2.2.3 פונק רגישות לפונקציונלים שונים :

נחשב את פונק הרגישות ב3 שלבים :

$$\bullet \text{ נחשב את } \dot{T}_F(F - G_t) = \lim_{t \rightarrow 0} \frac{T[(1-t)F + tG_t] - T(F)}{t} = \lim_{t \rightarrow 0} \frac{T[F + t(G_t - F)] - T(F)}{t} \text{ עבור } F \text{ ממש !!}$$

$G_t = \delta_x$ לאחר מכן מצהיר כי

\bullet נציב במקום F את \hat{F} אם נרצה לחשב את $V_{\hat{F}_n}$ בשביל רווח סמך אסימפטוטי

$$1. \text{ פונקציית רגישות עבור פונקציונל לינארי מהצורה } T(F) = \int x dF \text{ נקבל כי } L_F(x) = \dot{T}(\Delta_X - F) = \int \psi d[\Delta_X - F] = \psi - E_F(\psi)$$

$$2. \text{ פונקציית רגישות עבור אחוזון } T(F) = \min\{x \in \mathbb{R} \mid F(x) > p\} = F^{-1}(p) \text{ נקבל כי } L_F(x) = \dot{T}(\Delta_X - F) = \frac{p-1}{f(q)} \mathbb{1}_{\{q \geq x\}}$$

סייע בחישוב פונק רגישות $L_F(x)$: ראה דוגמא בפתרון בוחן לדוגמא משנה שעברה !

במידה ויש לנו פונקציונל מסובך ניתן להציג אותו בעזרת 2 פונקציונלים פשוטים שלהם אנו יודעים לחשב את $L_F(x)$ במקרה זה נגדיר $h \circ g(x) = h(T_0, T_1) = T_{\text{complex}}$ כאשר $g(x, y) = (T_0, T_1)$ ונקבל כי

$$\dot{h}(G_\varepsilon - F) = D(h \circ g) = Dh(g) \circ D(g) < \left(\frac{dh}{dT_0}, \left(\frac{L_{T_0(F)}}{dT_1} \right) \right) > = \frac{dh}{dT_0} \cdot L_{T_0(F)} + \frac{dh}{dT_1} \cdot L_{T_1(F)}$$

3 שיטת Bootstrap לאמידה של פונקציונלים ורווחי סמך.

מוטיבציה והערה חשובה :

\bullet הרעיון הוא כזה נניח ביצענו איזושהי אמידה לבעיה כלשהי וקיבלנו אומד נרצה לבחון אותו ואולי לשפר אותו על ידי הפחת $bias$ או הפחתת השונות.

\bullet נרצה להשתמש בבוטסטרפ אם נרצה לאמוד את השונות של האומד ולא נוכל לעשות זאת בצורה סגורה.

שיטת Bootstrap

נניח שישנו $T(F)$ פונקציונל הצבה ואנו מעוניינים לאמוד את ההטייה שלו כלומר את $Bias = E[T(F)] - T(F)$ או כל פונקציה אחרת למשל Ψ איך לקבל אומדי $Bootstrap$ הרבה פעמים נשתמש בשיטת $Bootstrap$ כדי לאמוד את השונות או את $bias$ של אומדי $M.L.E$ או הטייה של אומד לשונות וכולי

ובשלב II : נחסיר מהאומד $T(\hat{F}_n)$ את הטייה ונקבל אומד $Bootstrap$ עם הטייה נמוכה יותר לפעמים כלומר $\hat{T}_n^B \stackrel{\text{def}}{=} \text{Bootestimator} T(\hat{F}_n) - \hat{t}_n$ דוגמא הטייה של פונקציונל $T(F)$ הינה $t = E_F T(F) - T(F)$ נניח ויצא לנו כי $\hat{t}_n = E_{\hat{F}_n} T(F_n^*) - T(F_n^*)$ אז **אומד $Bootstrap$ עם הטייה מופחת הינו $T(F) - \hat{t}_n$** **היא מופחת מאשר ההטייה הטבעית של אותו האומד ראה דוגמא ברישומים של פבל או ראה דוגמא שאלה 4 בשיעורי בית !**

$$1. \text{ נעזר באומד ההצבה } \hat{F}_n \text{ ונגדיר } b_T(F) = ET(\hat{F}) - T(F) \text{ או באופן כללי } E_F \Psi(F, \hat{F}_n, t) = 0 \text{ כאשר כאן } t = b_T(F)$$

$$2. \text{ אחרי שהגדרנו את המשוואה שלנו נחליף אותה בצורה הבאה } E_{\hat{F}_n} \Psi(\hat{F}_n, F_n^*, t) = 0 \iff E_F \Psi(F, \hat{F}_n, t) = 0$$

$$(א) \text{ כעת מבחינתנו } \hat{F}_n \text{ ידועה ו} F_n^* \text{ לא ידועה כלומר } X_1^*, X_2^*, \dots, X_n^* | (\hat{F}_n) \stackrel{i.i.d}{\sim} F_n^*$$

$$i. \text{ שימוש לב כי } X_1^*, \dots, X_n^* \text{ מתפלג אחיד } \frac{1}{n} \text{ על ערכי המדגם המקורי } X_1, \dots, X_n$$

$$(ב) \text{ ניתן לדייק את } E_{\hat{F}_n} \Psi(\hat{F}_n, F_n^*, t) = 0 \text{ בעזרת שיטת מונטה קארלו}$$

$$i. \text{ נגדיר } F_n^{*(1)}, F_n^{*(2)}, \dots, F_n^{*(M)} \text{ נקבל } M \text{ פעמים ונקבל } F_n^{*(1)} = X_1^*, X_2^*, \dots, X_n^* | (\hat{F}_n) \stackrel{i.i.d}{\sim} F_n^*$$

$$ii. \text{ לפי החוק החזק של המספרים הגדולים נקבל כי } \frac{1}{M} \cdot \sum_{i=1}^M \Psi(\hat{F}_n, F_n^{*(j)}, t) \xrightarrow{M \rightarrow \infty} E_{\hat{F}_n} \Psi(\hat{F}_n, F_n^*, t)$$

3. המטרה הסופית בשיטת $Bootstrap$ זה להגיע מ $T(F_n^*)$ לביטוי שתלוי רק במדגם המקורי X_1, \dots, X_n !

\bullet **דוגמא פרקטית : נפעיל את שיטת bootstrap כדי לאמוד את bias של אומד ההצבה**

$$\text{נניח נתון אומד } T(F) = \left[\int x dF \right]^2 = \left[\overline{X_n} \right]^2 \text{ ונתון אומד הצבה } T(\hat{F}_n) = \left[\int x d\hat{F}_n \right]^2$$

ואנו רוצים לאמוד את ההטייה של אומד ההצבה.

\bullet דוגמא נוספת זה שימוש בשיטת $Bootstrap$ כדי לאמוד את השונות של הפונקציונל.

למה שיטת Bootstrap עובדת : שימוש ב2 המשפטים הבאים :

• נניח כי T גזירה הדמר עם פונק רגישות $L_F(x)$ המקיימת כי $\int_{\mathbb{R}} L_F(x)^2 dF < \infty$ פונק רציפה אזי

$$\sup_{u \in \mathbb{R}} |\mathbb{P}_F[\sqrt{n}[T(\hat{F}_n) - T(F)] < u] - \mathbb{P}_{\hat{F}_n}[\sqrt{n}[T(F_n^*) - T(\hat{F}_n)] < u]| \xrightarrow{\mathbb{P}} 0$$

• “ש ברי אנסן עידון של CLT : כאשר $\sup_{x \in \mathbb{R}} |\mathbb{P}_F(\sqrt{n} \cdot \frac{\bar{X} - \mu}{\sigma_F} \leq x) - \phi(x)| \leq \frac{1}{\sqrt{n}} \cdot \frac{\rho}{\sigma_F^3} \cdot C$ מספר קבוע !

• ראה הרצאה של פבל

אומד Bootstrap לשונות ולהטייה :

• אומד $Bootstrap$ להטייה : $\hat{t}_n = E_{\hat{F}_n}[T(\hat{F}_n^*)] - T(\hat{F}_n)$ עבור פונקציונל T כלשהו

• אומד $Bootstrap$ לשונות : $\hat{t}_n = E_{\hat{F}_n}[T(\hat{F}_n^*)]^2 - [E_{\hat{F}_n} T(\hat{F}_n)]^2$ עבור פונקציונל T כלשהו

3.1 שיטת Bootstrap לבנייה של רווחי סמך :

• **שיטה I :** רווח הסמך הינו $T(\hat{F}_n) \pm \hat{t}_n$ שזה שקול למשוואה

$$E_{\hat{F}_n} \psi(F_n^*, \hat{F}_n, t) = 0 \text{ כאשר } \hat{t}_n \text{ הוא פתרון המשוואה} \begin{cases} E_F \psi(\hat{F}_n, F, t) = 0 \\ \psi = 1_{\{|T(\hat{F}_n) - T(F)| < t\}} \end{cases} \iff \mathbb{P}_F[|T(\hat{F}_n) - T(F)| < t] = 1 - \alpha$$

דוגמא ישומית נחשב רווח סמך ל $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ עבור הפונקציונל $T(F) = \int x dF$ בעזרת אומדי $M.L.E$ שהם $\hat{\theta} = \left(\frac{\bar{X}}{S_n^2} \right)$

1. נפתור את המשוואה $E_{\hat{F}_n} \psi(F_n^*, \hat{F}_n, u) = 0$ שהיא שקולה ל

$$\mathbb{P}_F\left[\frac{\sqrt{n}}{S_n} \cdot |T(F_n^*) - T(\hat{F})| < \sqrt{n} \cdot \frac{t}{S_n}\right] = 1 - \alpha \iff \mathbb{P}_F[|T(F_n^*) - T(\hat{F})| < u] = 1 - \alpha$$

$$\hat{t} \stackrel{def}{=} \frac{Z_{1-\frac{\alpha}{2}}}{\sqrt{n} \cdot S_n} \iff \sqrt{n} \cdot \frac{t}{S_n} = Z_{1-\frac{\alpha}{2}} \text{ כלומר}$$

2. לכן הרווח סמך שלנו הינו

$$T(\hat{F}_n) \pm \frac{Z_{1-\frac{\alpha}{2}}}{\sqrt{n} \cdot S_n}$$

(א) **הערה בלבד :**

נציב את התוצאה במשוואה המקורית $E_F \psi(\hat{F}_n, F, \hat{t}) = 0$ ונקבל $\mathbb{P}_F[\sqrt{n} \cdot \frac{|T(\hat{F}_n) - T(F)|}{S_n} < Z_{1-\frac{\alpha}{2}}] = 1 - \alpha$ כאשר $G_{n-1, 1-\frac{\alpha}{2}}$ היא התפלגות t עם $n-1$ דרגות חופש.

$$i. \text{ ואז נקבל את רווח הסמך הבא : } T(\hat{F}_n) \pm \frac{G_{n-1, 1-\frac{\alpha}{2}}[Z_{1-\frac{\alpha}{2}}]}{\sqrt{n} \cdot S_n}$$

• **שיטה II : נקראת studentized bootstrap interval**

$$\hat{t}_n = \frac{1}{\sqrt{n}} \cdot G_{n-1}(1 - \alpha) \text{ ונקבל כי } \mathbb{P}_{F_n}[\sqrt{n} \cdot \frac{|\mu_{F_n^*} - \mu_{\hat{F}_n}|}{\sigma_{\hat{F}_n}} \leq \sqrt{n} \cdot t] = 1 - \alpha \iff \mathbb{P}_F[\frac{|\mu_{F_n} - \mu_F|}{\sigma_F} \leq t] = 1 - \alpha \text{ נביט במשוואה}$$

דוגמאות ישומיות :

• **רווח סמך בשיטת Bootstrap עבור** $T(F) = F(x_0)$ במקרה זה נקבל $\mathbb{P}_{\hat{F}_n}(n\hat{F}_n - nt \leq \sum_{i=1}^n 1_{\{X_i^* \leq x\}} \leq n\hat{F}_n + nt) = 1 - \alpha \iff$

$$\mathbb{P}_{\hat{F}_n}(|\hat{F}_n^*(x_0) - \hat{F}_n(x_0)| \leq t) = 1 - \alpha \iff \sum_{i=1}^n \binom{n}{k} \hat{F}(x_0)^k (1 - \hat{F}(x_0))^{n-k} = 1 - \alpha$$

ואז נקבל 7 ברישומים של פבל

• **רווח סמך בשיטת Bootstrap עבור** $T(F) = \int x dF$ ו $F \sim \exp(\lambda)$ נקבל כי $\mathbb{P}_F[\sqrt{n} \cdot \frac{|\bar{X}_n^* - \bar{X}_n|}{\bar{X}_n^*} \leq t] = 1 - \alpha \iff \mathbb{P}_F[\sqrt{n} \cdot \frac{|\bar{X}_n - \mu_F|}{\bar{X}_n} \leq t] = 1 - \alpha$

ונקבל כי $(n, 1)$ ראה תרגיל 3 שאלה 8 אצל פבל ! והרווח סמך הינו $T(\hat{F}_n) \pm \hat{t}_n$

3.2 סיוע בחישובים בשיטת Bootstrap :

$$\frac{1}{n} X_1^*, X_2^*, \dots, X_n^* \stackrel{i.i.d}{\sim} U[X_1, \dots, X_n] \cdot$$

$$E[S_n^2] = E\left[\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right] = (1 - \frac{1}{n})\sigma^2 \cdot$$

$$E[\frac{n}{n-1} \cdot S_n^2] = E[\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2] = \sigma^2 \cdot$$

$$\begin{cases} E_{\hat{F}_n}(X_1^* - X_1)^2 = Var(X_1^*) = S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - (\bar{X})^2 \\ E_{\hat{F}_n}(X_1^*) = \bar{X}_n \end{cases} : X_1^* \text{ חישוב בסיסי שלי תוחלת ושונות של } X_1^* \quad .1$$

$$\begin{cases} E_{\hat{F}_n}(\bar{X}_1^*) = E_{\hat{F}_n}(X_1^*) = \bar{X}_n \\ Var(\bar{X}_1^*) = \frac{Var(X_1^*)}{n} = \frac{1}{n} \cdot S_n^2 = \frac{1}{n^2} \sum_{i=1}^n (X_i - \bar{X})^2 \end{cases} : \bar{X}_1^* \text{ חישוב תוחלת ושונות של } \bar{X}_1^* \quad .2$$

$$E_{\hat{F}_n}\left[\frac{1}{n} \sum_{i=1}^n (X_i^*)^k\right] \stackrel{i.i.d \text{ samples}}{=} E_{\hat{F}_n}(X_1^*)^k = \frac{1}{n} \sum_{i=1}^n x_i^k = \bar{X}^k : X_1^* \text{ חישוב מומנטים של } X_1^* \quad .3$$

$$E_{\hat{F}_n}(X_1^*)^2 = S_n^2 + \bar{X}_n^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 = \bar{X}^2 \text{ עבור } k=2 \text{ נקבל } \quad (\alpha)$$

$$: (\bar{X}_1^*)^k \text{ חישוב מומנטים של ממוצע } \quad .4$$

$$E_{\hat{F}_n}(\bar{X}_1^{*k}) = E_{\hat{F}_n}(\bar{X}_1^* - \bar{X}_n + \bar{X}_n)^k = E_{\hat{F}_n}\left[\binom{n}{0}(\bar{X}_1^* - \bar{X}_n)^n + \binom{n}{1}(\bar{X}_1^* - \bar{X}_n)^{n-1} \cdot \bar{X}_n + \binom{n}{2}(\bar{X}_1^* - \bar{X}_n)^{n-2} \cdot (\bar{X}_n)^2 + \dots + (\bar{X}_n)^n\right]$$

$$E_{\hat{F}_n}(\bar{X}_n^* - \bar{X}_n) \cdot \bar{X}_n = 0 \text{ כי } E_{\hat{F}_n}(\bar{X}_n^* - \bar{X}_n) \cdot \bar{X}_n \text{ מהצורה ביטויים שהרי מתקיים } \quad (\alpha)$$

$$E_{\hat{F}_n}[\bar{X}_1^* - \bar{X}]^3 = E_{\hat{F}_n}\left[\frac{1}{n} \sum_{i=1}^n (x_i^* - \bar{X})\right]^3 = \frac{1}{n^3} \sum_{i=1}^n \sum_{j=1}^n \sum_{k=1}^n (x_i^* - \bar{X}) \cdot (x_j^* - \bar{X}) \cdot (x_k^* - \bar{X}) \text{ בנביט } \quad (\beta)$$

$$\begin{cases} i=j=k \\ i=j, i \neq k \\ i \neq j \neq k \end{cases} \text{ ונחפש ביטויים כלשהם כפול } E_{\hat{F}_n}(\bar{X}_n^* - \bar{X}_n) \cdot \text{ והם התאפסו } \quad (\gamma)$$

$$: k=3, k=4 \text{ חישובים סבוכים במומנטים } \quad (\delta)$$

$$E_{\hat{F}_n}(\bar{X}_n^* - \bar{X}_n)^3 = \frac{1}{n^2} \cdot \left[\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^3\right] \quad \text{i.}$$

$$E_{\hat{F}_n}(\bar{X}_n^* - \bar{X}_n)^4 = \frac{1}{n^3} \cdot \left[\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^4\right] + \frac{3n(n-1)}{n^4} \cdot \left[\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2\right]^2 \quad \text{ii.}$$

$$E_{\hat{F}_n}(\bar{X}_n^{*2}) = E_{\hat{F}_n}\left[\frac{1}{n} \sum_{i=1}^n x_i^{*2}\right] = Var_{\hat{F}_n}(\bar{X}^*) + [E_{\hat{F}_n}(\bar{X}^*)]^2 = \frac{1}{n} S_n^2 + (\bar{X}_n)^2 \text{ נקבל } k=2 \text{ עבור } \quad (\eta)$$

3.3 שיטת Jake - knife להקטנת ההטייה מתרגיל 3 שאלה 5

$$E_F T - \theta = \frac{a_F}{n} - \frac{b_F}{n^2} + O(n^{-3}) \text{ ש } \theta(F) \text{ ל } T \text{ אומד } \\ \text{כאשר } a_F, b_F \text{ הן פונקציות של המדגם} \\ \text{נגדיר אומד להטייה בשיטת } Jake - knife$$

$$\hat{B}_n^J = (n-1)(\bar{T}_n - T_n)$$

$$\bar{T}_n = \frac{1}{n} \sum_{i=1}^n T_{n/j} \text{ כאשר} \\ \text{אזי מתקיים כי}$$

$$E_F \hat{B}_n^J = \frac{a_F}{n} + O(n^{-2}) \quad .1$$

$$E_F T_n^J - \theta = O(n^{-2}) \text{ כי } T_n^J = T_n - \hat{B}_n^J \text{ אומד } Jake - knife \text{ נקבל } \quad .2$$

דוגמא ישומית של שיטת $Jake - knife$:
נניח ואנו רוצים לאמוד את $\theta = \mu^2$ אז אם $T = \overline{X^2}$ נקבל מסעיף א כי $E_F T - \theta = \frac{Var(x_1)}{n} - \frac{0}{n^2} + O(n^{-3})$
ואומד $Jake - knife$ יהיה

$$\overline{X^2} - \hat{B}_n^J = \overline{X^2} - (n-1)(\overline{T_n} - T_n) = \overline{X^2} - (n-1) \underbrace{\left(\frac{1}{n} \sum_{i=1}^n \left(\frac{1}{n-1} \sum_{i \neq j}^n x_i \right)^2 - \overline{X^2} \right)}_{\overline{T_n}}$$

4 אומדי $Kernel$ לפונקציית הצפיפות

נרצה לפתור את הבעיה הבאה בסטטיסטיקה $X_1, \dots, X_n \stackrel{i.i.d}{\sim} p \in \mathbb{R}$ כאשר p היא פונק צפיפות לא ידועה כלומר מניחים כי $\frac{d}{dx} F_x = p$
נשים לב כי אם באופן נהיבי נבחר לאמוד את F_x בעזרת $\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n 1_{\{X_i \leq x\}}$ נגלה כי אין משמעות לגזרת ומדובר בביטוי חסר משמעות

נשתמש ברעיון דומה :


נגדיר $\tilde{F}_{n,h}(x) = \frac{1}{n} \sum_{i=1}^n I\left(\frac{x-X_i}{h}\right)$ היא נקראת “smoothed” empirical distribution function
כאשר $I : \mathbb{R} \rightarrow [0, 1]$ עם תכונות של פונק התפלגות והיא גזירה ותתנהג כמעט כמו האינדיקטור !
כלומר $II\left(\frac{x-X_i}{h}\right)$ היא פונק שמקיימת את התכונות הבאות :

• I גזירה

• I פונק עולה חלש

$$\begin{cases} \lim_{x \rightarrow -\infty} I(x) = 0 \\ \lim_{x \rightarrow \infty} I(x) = 1 \end{cases}.$$

• נגדיר $h \lim_{h \rightarrow 0} I\left(\frac{x-X_i}{h}\right) = 1_{\{X_j \leq x\}}$ כ**י** **פס שמקיים** **כי**



איור 1 :

•

טענה מרכזית : מתקיים כי $\hat{F}_n(x) \xrightarrow{h \rightarrow 0} \tilde{F}_{n,h}(x)$ והיתרון כאן ברור הוא ש**גזירה** !
נגדיר אומד חדש p שהוא נקרא $Kernel Density Estimator$

$$\hat{p}(x) = \frac{1}{hn} \sum_{i=1}^n k\left(\frac{x-X_j}{h}\right)$$

כאשר k היא פונק קרנל שמקיימת

$$K(x) = \frac{d}{dx} I(x) \quad \bullet$$

$$\int_{\mathbb{R}} K(x) = 1 \quad \bullet$$

• ניתן לדרוש תכונות נוספות מ' K שהרי הוא פונקציה לבחירתנו

• נאמר כי K היא מסדר l אם מתקיים כי

$$\int_{\mathbb{R}} u^i K(u) du = 0, \quad i = 1, \dots, l$$

$$\int_{\mathbb{R}} |K(u)| \cdot |u|^{l+1} du < \infty \quad -$$

– אנו צריכים את ההגדרה הזו כדי לחסום את ההטייה בממד $MSE(\hat{p}(x_0), p(x_0))$

דוגמאות לפונק קרנלים נפוצות:

$$1. K(u) = \frac{1}{2} 1_{\{|u| \leq 1\}} \text{ אחידה}$$