

- חלקי דיון

- חלקי פונקציות, מקומות

בית 4 - שלש: 8

אלגוריתם NN-K (רדדסיה הוא)

$$\hat{f}(x) = \frac{1}{K} \sum_{j \in N_K(x)} y_j$$

כאשר  $N_K(x)$  היא קבוצה היא (נקס) של  $x$  הנקראת design הקרובות ביותר ל- $x$ .

(1) היא, הוואר  $\hat{f}(x)$  שני ל-  $\Sigma(\beta, L)$  עבור  $\beta$  כלשהו?

הערות:

-!  $\beta = \max\{k \in \mathbb{Z}_+, k \leq \beta\}$  (מספר)

הערות:  $f \in \Sigma(\beta, L)$  ו-  $f$  ו-

$$|f^{(\beta)}(x) - f^{(\beta)}(y)| \leq L |x - y|^{\beta-L} \quad \forall x, y \in \mathbb{R}$$

$$\left[ \begin{array}{l} f'(x) = a \quad \text{כאשר } L \leq \beta \\ f^{(\beta)}(x) = 0 \quad \text{אם } \beta < L \end{array} \right] \quad f(x) = ax + b \quad f \in \Sigma(1, L)$$

אם כן, נניח כי  $\hat{f}(x)$  היא פונקציה קבועה או קרובה מספיק בקרבת  $N_K(x)$  ל- $x$ . נניח כי  $N_K(x)$  היא קבוצה של  $K$  נקודות ו- $x$  היא נקודה אחת מהן. נניח כי  $N_K(x)$  היא קבוצה של  $K$  נקודות ו- $x$  היא נקודה אחת מהן.

(2) נניח כי  $X_j = \delta/n$  עבור  $j=1, \dots, n$ . נניח כי  $K$  הוא מספר קבוע.

האלגוריתם הוא מניח מספרים  $MSE$  ו-  $\Sigma(1, L)$ .

הערות:

- (מספר סכום)  $MSE$ , שווה ל-  $MSE$  (מספר) ו-  $MSE$  (מספר) ו-  $MSE$  (מספר).

- (מספר)  $MSE$  הוא

$$Y_i = f(x_i) + \epsilon_i; \quad \epsilon_i \text{ i.i.d. with } E\epsilon_i = 0, \text{Var}(\epsilon_i) = \sigma^2$$

- (מספר)  $MSE$  הוא

$$\text{Var}_f(\hat{f}(x_0)) = \mathbb{E}_f \left( \hat{f}(x_0) - \mathbb{E}_f \hat{f}(x_0) \right)^2 = \mathbb{E}_f \left( \frac{1}{k} \sum_{j \in N_k(x_0)} Y_j - \frac{1}{k} \sum_{j \in N_k(x_0)} f(x_j) \right)^2$$

$$\left\{ \begin{aligned} \mathbb{E}_f \hat{f}(x_0) &= \mathbb{E}_f \frac{1}{k} \sum_{j \in N_k(x_0)} Y_j \\ &= \frac{1}{k} \sum_{j \in N_k(x_0)} \mathbb{E}_f Y_j = \frac{1}{k} \sum_{j \in N_k(x_0)} f(x_j) \end{aligned} \right.$$

הערות:  
הערות  
הערות

$$Y_j = f(x_j) + \varepsilon_j$$

$$= \mathbb{E}_f \left( \frac{1}{k} \sum_{j \in N_k(x_0)} \varepsilon_j \right)^2 = \frac{1}{k^2} \cdot \underbrace{|N_k(x_0)|}_{k} \cdot \sigma^2 = \frac{\sigma^2}{k}$$

(הערות: k)

הערות

הערות

$$|\mathbb{E}_f \hat{f}(x_0) - f(x_0)| = \left| \frac{1}{k} \sum_{j \in N_k(x_0)} f(x_j) - f(x_0) \right|$$

$$\stackrel{\text{design}}{=} \left| \frac{1}{k} \sum_{j \in N_k(x_0)} (f(j/n) - f(x_0)) \right|$$

$$\leq \frac{1}{k} \sum_{j \in N_k(x_0)} |f(j/n) - f(x_0)|$$

$$\leq \frac{1}{k} \sum_{j \in N_k(x_0)} L \cdot |j/n - x_0|$$

$$= \frac{L}{k} \sum_{j \in N_k(x_0)} |j/n - x_0|$$

הערות:  
הערות  
הערות

$$\leq \frac{2L}{kn} \sum_{j=1}^{k/2} j \leq 2L \cdot \frac{k}{n}$$

$$|j/n - x_0| \leq |j/n|$$

$$\mathbb{E}_f (\hat{f}(x_0) - f(x_0))^2 \leq \frac{\sigma^2}{k} + \left( 2L \frac{k}{n} \right)^2 =: g(k)$$

הערות

$$g'(k) = -\frac{\sigma^2}{k^2} + 2 \cdot 2L \frac{k}{n} \cdot \frac{2L}{n} = -\frac{\sigma^2}{k^2} + \frac{8L^2}{n^2} \cdot k \stackrel{!}{=} 0$$

$$\Leftrightarrow \frac{8L^2}{n^2} k = \frac{\sigma^2}{k^2} \quad (\Leftrightarrow) \quad k^3 = \sigma^2 \cdot \frac{n^2}{8L^2} \quad \Rightarrow \quad \boxed{k^3 = C(L, \sigma) \cdot n^{2/3}}$$

# Local Polynomial Estimators - 5 ד"ר

Let i.i.d. data  $(X_1, Y_1), \dots, (X_n, Y_n)$  from  $f$  and  $\epsilon_j$  - i.i.d.

$$Y_j = f(X_j) + \epsilon_j$$

$\epsilon_j$  - i.i.d.

$$E\epsilon_j = 0 \quad E\epsilon_j^2 = 1$$

Let Nadaraya-Watson kernel,  $h$  - bandwidth

$$\hat{f}_h(x) = \frac{\sum_{i=1}^n Y_i K\left(\frac{x-X_i}{h}\right)}{\sum_{i=1}^n K\left(\frac{x-X_i}{h}\right)}$$

Kernel

Bandwidth

$K$  - kernel,  $h$  - bandwidth

$$\hat{f}_h(x) = \arg\min_{\theta \in \mathbb{R}} \sum_{j=1}^n (Y_j - \theta)^2 K\left(\frac{x-X_j}{h}\right)$$

Let  $f$  be  $l$ -times differentiable at  $x$ . Then

$$f(z) = f(x) + f'(x)(z-x) + \dots + \frac{1}{l!} f^{(l)}(x)(z-x)^l + o((z-x)^l)$$

$$= \theta(x)^T U\left(\frac{z-x}{h}\right) + o((z-x)^l)$$

$$\theta(x)^T = (f(x), f'(x)h, \dots, f^{(l)}(x)h^l) \quad ; \quad U(t) = (1, t, \frac{1}{2!}t^2, \dots, \frac{1}{l!}t^l)$$

Let  $X_j$  - data point,  $x$  - point

$$Y_j = \theta(x)^T U\left(\frac{X_j-x}{h}\right) + o((X_j-x)^l) + \epsilon_j$$

$$\hat{\theta}(x) = \arg\min_{\theta \in \mathbb{R}^{l+1}} \sum_{j=1}^n \left(Y_j - \theta^T U\left(\frac{X_j-x}{h}\right)\right)^2 K\left(\frac{x-X_j}{h}\right)$$

Local Polynomial Estimator of order  $l$   $\rightarrow \hat{f}_h(x) := \hat{\theta}(x)^T U(0)$

Let  $N-W$  kernel,  $h$  - bandwidth,  $l$  - order

Let  $h$  - bandwidth,  $l$  - order,  $N-W$  kernel,  $Y_j$  - data point

הפונקציה  $B_n(x)$  נקראת

נעזר

$$\hat{\theta}(x) = B_n(x)^{-1} a_n(x) \quad (*)$$

$$a_n(x) = \frac{1}{nh} \sum_{j=1}^n y_j U\left(\frac{x_j - x}{h}\right) K\left(\frac{x - x_j}{h}\right)$$

$$B_n(x) = \frac{1}{nh} \sum_{j=1}^n U\left(\frac{x_j - x}{h}\right) U\left(\frac{x_j - x}{h}\right)^T K\left(\frac{x - x_j}{h}\right)$$

הפונקציה  $f$  היא LP רציפה,  $p$  ו- $q$

הפונקציה  $f$  היא LP רציפה,  $p$  ו- $q$

$$\hat{f}(x) = \sum_{j=1}^n y_j W_{nj}(x)$$

$$W_{nj}(x) = \frac{1}{nh} U^T(0) B_n(x)^{-1} U\left(\frac{x_j - x}{h}\right) K\left(\frac{x - x_j}{h}\right)$$

||

הפונקציה  $f$  היא LP רציפה,  $p$  ו- $q$

הפונקציה  $f$  היא LP רציפה,  $p$  ו- $q$

הפונקציה  $f$  היא LP רציפה,  $p$  ו- $q$

$$g(\theta) = \sum_{i=1}^n (y_i - \theta^T v_i)^2 K_i$$

$$v_i \in \mathbb{R}^{L+1}, K_i \in \mathbb{R}$$

$$f_i(\theta) = (y_i - \theta^T v_i)^2$$

$$\nabla f_i(\theta) = 2(y_i - \theta^T v_i) v_i^T$$

$$\Rightarrow \nabla g(\theta) = \sum_{i=1}^n \nabla f_i(\theta) K_i = \sum_{i=1}^n 2(y_i - \theta^T v_i) v_i^T K_i$$

$$= \sum_{i=1}^n 2 y_i v_i^T K_i - 2 \sum_{i=1}^n \theta^T v_i v_i^T K_i \stackrel{!}{=} 0$$

$$\Rightarrow \theta^T \underbrace{\sum_{i=1}^n v_i v_i^T K_i}_{\text{מטריצה}} = \underbrace{\sum_{i=1}^n y_i v_i^T K_i}_{\text{וקטור}}$$

הפונקציה  $f$  היא LP רציפה,  $p$  ו- $q$

$$\theta^T = \left( \sum_{i=1}^n y_i v_i^T K_i \right) \cdot \left( \sum_{i=1}^n v_i v_i^T K_i \right)^{-1}$$

$$\Rightarrow \hat{\theta} = \left( \sum_{i=1}^n v_i v_i^T K_i \right)^{-1} \left( \sum_{i=1}^n y_i v_i^T K_i \right)$$

הפונקציה  $f$  היא LP רציפה,  $p$  ו- $q$

$$y_i = y_i \in \mathbb{R}; v_i = U\left(\frac{x_i - x}{h}\right) \in \mathbb{R}^{L+1}; K_i = K\left(\frac{x - x_i}{h}\right) \in \mathbb{R}$$



...  $f'$  ...  $f$  ...  $l=1$  ...  $L$  ...  $h$  ...

...  $h$  ...

...  $l=1$  ...

$$\Theta(x)^T = (f(x), f'(x)h)$$

$$U^T(t) = (1, t)$$

...  $\hat{f}'$ ,  $\hat{f}$ ,  $\hat{\theta}$  ...

$$\hat{\theta}(x) = B_n^{-1}(x) a_n(x) \quad ; \quad \hat{f}(x) = \hat{\theta}(x)^T U(0) \quad ; \quad \hat{f}'(x) = \frac{1}{h} \hat{\theta}(x)^T U'(0)$$

$$* B_n(x) = \frac{1}{nh} \sum_{i=1}^n U\left(\frac{x_i - x}{h}\right) U\left(\frac{x_j - x}{h}\right)^T K\left(\frac{x - x_j}{h}\right)$$

$$* U(t) U(t)^T = \begin{pmatrix} 1 \\ t \end{pmatrix} \begin{pmatrix} 1 & t \end{pmatrix} = \begin{pmatrix} 1 & t \\ t & t^2 \end{pmatrix}$$

$$= \frac{1}{nh} \sum_{i=1}^n \begin{pmatrix} 1 & \frac{x_j - x}{h} \\ \frac{x_i - x}{h} & \left(\frac{x_i - x}{h}\right)^2 \end{pmatrix} K\left(\frac{x - x_j}{h}\right)$$

$$= \frac{1}{nh} \begin{pmatrix} \sum_{i=1}^n K\left(\frac{x - x_j}{h}\right) & \sum_{i=1}^n \frac{x_i - x}{h} \cdot K\left(\frac{x - x_j}{h}\right) \\ \sum_{i=1}^n \frac{x_i - x}{h} K\left(\frac{x - x_j}{h}\right) & \sum_{i=1}^n \left(\frac{x_i - x}{h}\right)^2 K\left(\frac{x - x_j}{h}\right) \end{pmatrix} =: \frac{1}{nh} \cdot \begin{pmatrix} S_0 & S_1 \\ S_1 & S_2 \end{pmatrix}$$

$$* a_n(x) = \frac{1}{nh} \sum_{j=1}^n Y_j \cdot U\left(\frac{x_j - x}{h}\right) K\left(\frac{x - x_j}{h}\right) = \frac{1}{nh} \begin{pmatrix} \sum_{j=1}^n Y_j \cdot K\left(\frac{x - x_j}{h}\right) \\ \sum_{j=1}^n Y_j \cdot \frac{x_j - x}{h} \cdot K\left(\frac{x - x_j}{h}\right) \end{pmatrix} =: \frac{1}{nh} \cdot \begin{pmatrix} T_0 \\ T_1 \end{pmatrix}$$

$$\Rightarrow \hat{\theta}(x) = B_n^{-1}(x) a_n(x) = \frac{1}{S_0 S_2 - S_1^2} \cdot \begin{pmatrix} S_2 & -S_1 \\ -S_1 & S_0 \end{pmatrix} \cdot nh \cdot \frac{1}{nh} \cdot \begin{pmatrix} T_0 \\ T_1 \end{pmatrix} = \frac{1}{S_0 S_2 - S_1^2} \cdot \begin{pmatrix} S_2 T_0 - S_1 T_1 \\ -S_1 T_0 + S_0 T_1 \end{pmatrix}$$

$$\Rightarrow \hat{f}(x) = \hat{\theta}(x)^T U(0) = \frac{S_2 T_0 - S_1 T_1}{S_0 S_2 - S_1^2}$$

$$\Rightarrow \hat{f}'(x) = \frac{1}{h} \cdot \hat{\theta}(x)^T U'(0) = \cancel{\frac{1}{h} \cdot \hat{\theta}(x)^T} \cdot \cancel{\begin{pmatrix} 0 \\ 1 \end{pmatrix}} = \frac{1}{h} \cdot \frac{S_0 T_1 - S_1 T_0}{S_0 S_2 - S_1^2}$$

$$U'(t) = (0, 1)$$

//