

תוכן העניינים

1	טרמינולוגיה ותזכורת מבוא לסטטיטיקה ותורת ההסתברות
2	פונקציית נראות
3	אומדנים לפי שיטת המומנטים מסדר 1
4	אומדנים לפי שיטת נראות מירבית
4	התפלגות רב נורמלית ותכונות שלה
5	תכונות בסיסיות של התפלגיות חשובות
6	משפט הגבול המרכזי החולש והחזק של חמש פרמיים גדולים
8	פונקציית מומנטים ופונקציית אופיינית
9	כל האישונים החשובים בהסתברות
10	
2	מודלים סטטיסטיים
11	מספיקות ומשפט הפירוק של פישר נימן
12	אלמנטים בתורת החלטות
13	3. גישות לבוחר באומד האופטימי
14	1.2. אמידה בייסאנית
15	2. אומדנים חסרי הטיה
17	3.2. התכנסות של משתנים מקרים
18	1.3.2. סדר בראש על כל ההתכנסויות השונות הייחסים ביניהם
19	4.2. אמידה במדגמים גדולים
20	5.2. רוחח סמך מדויקים ומקרובים
21	6.2. בדיקת השערות
22	1.6.2. בדיקת השערות התפלגיות מוכרכות - מיכה
22	2.6.2. הלמה של נימן פירסון
23	3.6.2. בדיקת השערות מורכבות
24	
3	דוגמאות נגדירות חשובות

1 טרמינולוגיה ותזכורת מבוא לסטטיטיקה ותורת ההסתברות

X מרחב מדגם

מדבר במשנה מקרים עם התפלגות P קרי $\mathbb{P} \sim X$

הגדרה לפ' תורת ההסתברות -

ימי Ω מרחב מדגם בדיד. משתנה מקרי (מי'ם) על מרחב זה הוא
 הפונק $\mathbb{R} \rightarrow \Omega$: X נאמר ש X מוגדר על כל מרחב החסתברות (Ω, F, P) (שהזו מרחב המדגם העורו

1. נניח כי $\Omega \rightarrow \mathbb{R}$: X, Y שני מי'ם שמוגדרים על אותו מרחב הסתברות (Ω, F, P) או גם
 $X \cdot \alpha + Y$ או $X \cdot \alpha$ הם מי'ם ע"ש טווח שונה שמוגדרים על אותו מרחב

הנחה נוספת היא שאנו לא יודעים מהי \mathbb{P} ושhai ישיכת למשפחה של התפלגיות (Θ) שתלוויות בפרמטר θ
 $\mathcal{P} = \{\mathbb{P}_\theta, \theta \in \Theta\}$

הגדרה 2.1 סטטיסטי

הדרך להסביר מהו θ בעזרת סטטיסטי שהוא משתנה של הנתונים שיש לנו מרחב המדגם.
 סטטיסטי הוא משתנה מקרי שמתואר בעזרת הנתונים שיש לנו בלבד ולא בעזרת פרמטרים אותם
 אנחנו רוצחים לאמוד
 הדרך להסביר מהי θ מתחלת ל 3 חלקים

1. אמידה נקודתית

2. רוחח סמך

3. בדיקת השערות

p.m.f 3.1 הגדרה

פונקציית *probability mass functions*
 $\mathbb{P}_\theta(X = x) = p_\theta(x)$:

הגדרה 4.1 פונק התפלגות מצטברת *c.d.f*
 $\mathbb{P}_X((-\infty, x]) = \mathbb{P}(X \leq x) = F_x(x)$

טענה 5.2 דרכיים למצוא את $f_x(x)$

1. هي X مُشَتَّنة مُكَرِّي بِعَلْ صَفَيْفَات f_x وَتَهْي $\mathbb{R} \rightarrow \mathbb{R}$: g فَوْنَقِيَّة مُونَمَش وَجَزِيرَة $y \in \mathbb{R}$ مُوكَيِّمَيْن C

$$f_Y(s) = \frac{f_X(s)}{|g'(s)|} = f_X(g^{-1}(s)) (g^{-1})'(s) = \frac{f_X(g^{-1}(s))}{g'(g^{-1}(s))}$$

عَمُود 155 بِسَفَر شَلَّ أَوْهَد رَاهَ دَوْغَمَاء تَرْجِيل 12
تَمِيد نَحْسَب مِيْهَم $(g(x) \text{ و } g'(x))$ وَأَزَّ نَصِيب بِنَوْسَهَا
 $g^{-1}(x) = x - c$ $x \sim Exp(1)$ $c + x \sim Exp(1)$ $x = c + y$ مُونَعِلَّه وَجَزِيرَه 1
وَمَتَكَيِّمَيْن $g'(x) = 1$ $g(x) = c + x$ $y \sim Exp(1)$
 $f_x(s) = \begin{cases} e^{-(s-c)} & s \geq 0 \\ 0 & s < 0 \end{cases}$ **عَتَّ**

2. دَرَك شَنِيَّه لِمَذَاؤَه لِلْحَصَب مَهَوْ ($f_x(X \leq x)$) وَأَزَّ لِعَشَوْت ($F_X(x) = f_x(X \leq x)$)

طَعَنَه 6.1 طَعَنَه حَشُوبَه مَهَاسِتَبَرَوْتَ عَبَور مَهَاسِتَبَرَوْتَ مَكَرِّيَمَ بَدِيَّيْمَ
يَهِي X, Y مَشَتَّنَيْمَ مَكَرِّيَمَ شَوَّي التَّفَلَّغَوْتَ لَأَبَهَرَه مَأَوَّتَه مَرَّاصَبَه السَّتَّبَرَوْتَ وَتَهْي $f : \mathbb{R} \rightarrow \mathbb{R}$
عَمُود 65 بِسَفَر شَلَّ أَوْهَد تَوْرَتَه السَّتَّبَرَوْتَ

طَعَنَه 7.1 طَعَنَه مَمْبَأَه لَسَطَطِيَّيَّه الرَّصَّاه 2
تَمِيد اَس $n \in X$ اَسْبَار لَهَجَدَي $E(x^2) = ||x||^2$ يَش لَّوَه تَكُونَه شَلَ سَمِي نُورَمَه كَلَمَر بَلِي الدَّرِيشَه شَلَّ حَيَّبَيَّه بَهَّالَتْ !
لَكَن عَلَ طَعَنَه شَلَّ اَمَّا مَتَبَسَّسَه عَلَ زَهَّ نَيَّنَوْتَه لِشِيمَوْشَ

طَعَنَه 8.1 اَيِّنِدِيكَتُور 1_{x ∈ A}
اَيِّنِدِيكَتُور مَوْجَدَر $\begin{cases} P(A) & x = 1 \\ 1 - P(A) & x = 0 \end{cases}$
الْفَوْنَقِيَّة 1_{x ∈ A} شَوَّه لَّوَه اَس A مَتَكَيِّمَه اَخَرَه 0
طَرِيَّكَيْمَ

1. نَسِيمَ لَبَّيْ مَتَكَيِّمَيْمَ 3 $\prod_{i=1}^n 1_{\{x_i - \mu \geq 0\}} = 1_{\{\min x_i \geq \mu\}}$ طَعَنَه كَمَسْكَنَه مَتَرْجِيل

2. اَم x_1, \dots, x_n مَوْعِدَه اَيِّي 2018 مَرَوَعَيِّه الْمَلَّه ! $\sum_{i=1}^n 1_{\{x_i \geq l\}} - n = - \sum_{i=1}^n 1_{\{x_i < l\}}$ اَيِّي $x_1, \dots, x_n \stackrel{i.i.d.}{\sim}$

1.0.1 فَوْنَقِيَّيَّتَه نَرَأَوَتَه

طَعَنَه 9.1 فَوْنَقِيَّيَّتَه نَرَأَوَتَه شَل X_1, \dots, X_n دَجِيمَه بَهَّت
يَهِي X_1, \dots, X_n مَدَجَمَه مَكَرِّيَمَ دَجِيمَه بَهَّت بَشَنِيَّيَّه الدَّجِيمَوْتَ بَأَوْ صَفَيْفَاتَه
يَهِي X_1, \dots, X_n مَدَجَمَه مَكَرِّيَمَ دَجِيمَه بَهَّت بَشَنِيَّيَّه الدَّجِيمَوْتَ بَأَوْ صَفَيْفَاتَه
يَهِي X_1, \dots, X_n مَدَجَمَه مَكَرِّيَمَ دَجِيمَه بَهَّت بَشَنِيَّيَّه الدَّجِيمَوْتَ بَأَوْ صَفَيْفَاتَه بَسَلَّه بَدِيَّه اَيِّي
 $L(x; \theta) := \prod_{i=1}^n f_\theta(X_i) + \prod_{i=1}^n \mathbb{P}_\theta(X_i)$.
الْهَنَّاه نَسَفَتَه يَهَا شَل x_j هَوَّ كَبُوْعَه مَمَشَ بِيَهَسَ 1
فَوْنَقِيَّيَّتَه نَوَّاه يَكُولَه لَكَبَلَ عَرَقَيْمَه جَدَلَيْمَه 1
فَوْنَقِيَّيَّتَه نَرَأَوَتَه شَل دَجِيمَه بَوْدَدَت X
شَيْمَه لَبَّيْ شَكَشَه مَبَشَيْمَه مَمَنِي لَمَذَاؤَه $f.p.m.$ لَلَّمَرَه فَوْنَقِيَّيَّتَه الْهَتَّفَلَّوْتَه
فَوْنَقِيَّيَّتَه نَرَأَوَتَه هَيَا $f(x|\theta)$ $L(x; \theta) := f(x|\theta)$ اَسْبَار فَوْنَقِيَّيَّتَه الْهَتَّفَلَّوْتَه
اَس X هَوَّ مَشَتَّنَه مَكَرِّيَمَ دَجِيمَه بَهَّت $L(x; \theta) := p(x|\theta)$ اَسْبَار $p(x|\theta)$ هَيَا فَوْنَقِيَّيَّتَه صَفَيْفَاتَه
اَس X هَوَّ مَشَتَّنَه مَكَرِّيَمَ دَجِيمَه بَهَّت $L(x; \theta) := p(x|\theta) + p(x; \theta)$ اَسْبَار فَوْنَقِيَّيَّتَه السَّتَّبَرَوْتَ
نَسِيمَ لَبَّيْ شَلَّه $L(x; \theta) = P(X|\theta)$ لَمَرَوَتَه θ لَأَيْدِيه وَأَنَّوْ مَنِيسَه لَأَمَدَه اَوَّهَه يَوَدَعَه مَيْهَم X
هَهَه شَهَكَه تَفَكَّيدَه اَمَمِيدَه بَاهِسَانَيَّه !!

دَوْغَمَاء لَهَتَّفَلَّوْتَه بَلِي فَوْنَقِيَّيَّتَه نَرَأَوَتَه
نَنِيَّه وَيَش لَيْ مَطَبَعَه عَمَّه زَادَ رَاهَشَه وَزَادَ شَنِيَّه θ
 $\mathbb{P}_\theta = \begin{cases} \theta & x = \theta \\ 1 - \theta & x = 0 \end{cases}$ كَاهَشَه

X_1, \dots, X_n دَجِيمَوْتَه شَل الْهَتَّلَوْتَه مَطَبَعَه

اَزَّيِّه لَأَنَّوْلَه X فَوْنَقِيَّيَّتَه نَرَأَوَتَه ! كَيْه x_j تَلَويَّه بَهَّه

نَرَأَوَتَه شَل الْهَتَّفَلَّوْتَه بَنَوَلَيِّي

$L(x, \theta) = \theta^{\sum_{i=1}^n x_i} \cdot (1 - \theta)^{n - \sum_{i=1}^n x_i}$

نَرَأَوَتَه شَل الْهَتَّفَلَّوْتَه فَوَاسَّعَه

$L(\lambda) = \prod_{i=1}^n e^{-\lambda} \cdot \frac{\lambda^{x_i}}{x_i!} = e^{-n\lambda} \cdot \frac{\lambda^{\sum_{j=1}^n x_j}}{\prod_{j=1}^n x_j!}$

$l(\lambda) = \log(L(\lambda)) = -n\lambda + \sum_{i=1}^n x_i \log \lambda - \sum_{i=1}^n \log(x_i!)$

נראות של בינומית

$$X_1, \dots, X_n \stackrel{i.i.d}{\sim} bin(n, p)$$

$$L(p) = \prod_{i=1}^n \mathbb{P}(X_i = x_i) = \prod_{i=1}^n \binom{n}{x_i} p^{x_i} (1-p)^{n-x_i}$$

$$\ell(p) = (\sum_{i=1}^m X_i) \log\left(\frac{p}{1-p}\right) + n \cdot m \log(1-p) + \log(C)$$

נראות של נורמלית

$$X_1, \dots, X_n \stackrel{i.i.d}{\sim} N(\mu, \sigma^2)$$

$$L(\mu, \sigma^2) = \frac{1}{(\sqrt{2\pi\sigma^2})^n} \cdot e^{-\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}}$$

$$\ell(\mu, \sigma^2) = \frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}$$

נראות של התפלגות איחידה

$$L(a, b) = \frac{1}{(b-a)^n} \prod_{i=1}^n 1_{\{a \leq X_i \leq b\}} = \frac{1}{(b-a)^n} 1_{\{1 \leq \min X_I\}} \cdot 1_{\{\max X_i \leq b\}}$$

נראות של התפלגות גמא

$$X_1, \dots, X_n \stackrel{i.i.d}{\sim} \Gamma(\alpha, \beta)$$

$$\ell(r, \lambda) = -\lambda \sum_{i=1}^n x_i + (r-1) \sum_{i=1}^n \log(x_i) + r \cdot n \cdot \log(\lambda) - \log(\Gamma(r))$$

נראות של התפלגות מעריכית

$$X_1, \dots, X_n \stackrel{i.i.d}{\sim} Exp(\theta)$$

$$l(X, \theta) = n \cdot \ln \theta - \theta \sum_{i=1}^n X_i$$

נראות של התפלגות פרטו

$$l(X, \theta) = n \cdot \ln \theta + n \theta \ln c - (\theta + 1) \sum_{j=1}^n \ln X_j$$

2.0.1 אומדיים לפי שיטת המומנטים מסדר 1

$$X_1, \dots, X_n \stackrel{i.i.d}{\sim} \text{יהם}$$

טענה 10.1 אומדיים בשיטת המומנטים

$$m_k(X) = \mathbb{E}(X^k) \quad k \text{ מומנטי}$$

$$E_{\hat{\theta}}(X^k) = \frac{1}{n} \sum_{i=1}^n X_i^k$$

$$E[X_i] = \bar{X}$$

טבלה 1 : שיטת מומנטים

אומדן מומנטי	התפלגות
$\bar{X} = \lambda$	$X \sim Po(\lambda)$
$\bar{X} = \mu \cdot \sigma^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$	$X \sim N(\mu, \sigma^2)$
$b = 2\bar{X}$	$X \sim U(0, b)$
$\hat{\lambda} = \frac{\bar{X}}{\hat{\sigma}^2} \cdot \hat{r} = \frac{\bar{X}^2}{\hat{\sigma}^2}$	$X \sim Gamma(\lambda, r)$
$\lambda = \frac{1}{\bar{X}}$	$X \sim Exp(\lambda)$
$\hat{p} = \frac{\bar{X}}{n}$	$X \sim Bin(n, p)$

3.0.1 אומדיים לפי שיטת נראות מירבית

$$X_1, \dots, X_n \stackrel{i.i.d}{\sim} \text{יהם}$$

טבלה 2 : אומדיים בשיטת נראות מירבית

אומדן מירבי	התפלגות
$\hat{\lambda} = \bar{X}$	$X \sim Po(\lambda)$
$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^2, \hat{\mu} = \bar{X}$	$X \sim N(\mu, \sigma^2)$
$\hat{a} = \min_{i \in [n]} X_i$	$X \sim U(a, b)$
$\hat{b} = \max_{i \in n} X_i$	
$\hat{\theta} = \frac{n}{\sum_{i=1}^n X_i} = \frac{1}{\bar{X}}$	$X \sim Exp(\theta)$
$\hat{p} = \bar{X}$	$X \sim Bin(n, p)$
$\hat{P} = \bar{X}$	$X \sim ber(p)$
$\hat{\theta} = \bar{X}$	$X \sim Geo(\frac{1}{\theta})$

טענה 11.1

4.0.1 התפלגות רבת נורמלית ותכונות שלה

הגדלה 12.1 נאמר שוקטור W הוא מתפלג רק נורמלי אם ניתן להציג אותו כך $W = \mu + AZ$ כאשר $A \in \mathbb{R}^{m \times n}$ ו- $Z \sim N(0, I_n)$

בහיבט האינטואיטיבי כל קורדיינטה היא משתנה מקרי נורמלי חד מימדי כמו בתורת ההסתברות

-הגדלה שקופה לפיה ויקפidea $W \sim N(\mu, \sum)$ מתפלג רב נורמי כך ש (w_1, \dots, w_n) הם וקטורי תוחלות (μ_1, \dots, μ_n)

ומטריצת שונות משותפות $\sum_{i,j} = E[(X_i - \mu_i)(X_j - \mu_j)] = cov(X_i, X_j)$

תכונות בסיסיות

$$E(W) = \mu \quad cov(W) = AA^T \quad .1$$

2. אם $m = q$ כלומר A מטריצה הפיכה איזו פונקציית הצפיפות של W היא $f_W(w) = (2\pi)^{-\frac{m}{2}} \cdot det(V)^{-\frac{1}{2}} exp(-(w-\mu)^T V^{-1}(w-\mu)/2)$

3. אם $W^1 \stackrel{d}{=} W^2$ אז $\mu_1 = \mu_2$ וגם $A^1 A^{1T} = A^2 A^{2T}$ מדבר במספר לעיל ולא בחזקה!

4. אם $C \in \mathbb{R}^{m \times m}$ והוא מטריצה רק נורמי ו- $W \sim N(\mu, V)$ וקטורי קבועים איזו $C^T w \sim N(C^T \mu, C^T V C)$

5. אם $c \in \mathbb{R}^m$ מתקיים כי $c^T W \sim N(c^T \mu, c^T V c)$

(א) מסקנה מגניבת כל וקטורי שהוא מתפלג נורמי איזו כל תות וקטורי שלו התפלג נורמי גם כן! כי אני יכול לבחור סקלר שיופיע איזו קורדיינטה שאני רוצה!

i. ב- W כך ש c^T תות וקטורי של W התפלג נורמי

(ב) טרנספורמציות לינאריות של משתנים שמתפלגים נורמליים הם עידיון התפלגות נורמלית!

6. אם $W \in \mathbb{R}^m$ כך ש $W \sim N(\mu, V)$ ו- $C \in \mathbb{R}^{m \times n}$ איזו מתקיים כי $CW \sim N(C\mu, CVC^T)$

7. יהיו n משתנים מקרים מתפלגים נורמי קרי $W_1, \dots, W_k \sim N(\mu_k, V^k)$ לא בהכרח זהים!

(א) והוא $d_k \dots d_1$ וקטוריים קבועים איזו מתקיים כי $\sum_{k=1}^K d_k W_k \sim N(\sum_{k=1}^K d_k \mu_k, \sum_{k=1}^K d_k^2 V^k)$

8. נניח כי $Cov(W_r, W_s) = V_{rs} = 0$ for $r \in L_1$ and $s \in L_2$ כך ש L_1, L_2 כל

(א) איזו $\{W_s | s \in L_2\}$ ו- $\{W_r | r \in L_1\}$ אם **המשתנים מתפלגים רב נורמלי!**

$$\begin{pmatrix} x_1 \\ x_2 \\ y_1 \\ y_2 \\ y_3 \end{pmatrix}$$

(ב) נשים לב שלא מדובר במטריצה שוניות 0 זהותית! נניח יש לי את הוקטור זהותית x_1, x_2, y_1, y_2, y_3 הם בלתי תלויים אף על פי שהם מתקבלים מחלוקתם של y_1, y_2, y_3 ב- X, Y גורר ש $cov(X_i, Y_j) = 0$ או

תלוויים אבל!

זה לא גורר ש x_1, x_2, y_1, y_2, y_3 הם בלתי תלויים או ש y_1, y_2, y_3 הם בלתי תלויים אף על פי שהם מתקבלים מחלוקתם של x_1, x_2 וזהותית!

(ג) מסקנה אם X, Y מתפלגים נורמליים וגם $Cov(X, Y) = 0$ איזו X, Y הם בלתי תלויים?

טענה 13.1 טריקים על תוחלת $\mathbb{E}(x)$

$$1. \text{ אם } X, Y \text{ מ"מ ב"ת איזו } \mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y)$$

$$2. \text{ קבוע } a \mathbb{E}(a) = a$$

3. **תכונות התוחלת המותנית** $f(Z) = f(X, Y, Z)$ נזכר בהגדלה של תוחלת מותנית

$$f(a) = \begin{cases} E[Y|X=a] & P(X=a) > 0 \\ 0 & P(X=a) = 0 \end{cases}$$

(א) לini $\mathbb{E}[X+Y|Z] = \mathbb{E}[X|Z] + \mathbb{E}[Y|Z]$

(ב) **תכונת הרכבה** $\mathbb{E}[\mathbb{E}[X|Z]|W] = \mathbb{E}[X|W]$

(ג) מונו אם $\mathbb{E}[X|Z] \stackrel{a.s}{\geq} \mathbb{E}[Y|Z]$ אז $X \stackrel{a.s}{\geq} Y$

(ד) **הוצאת החלק הידוע** $\mathbb{E}[XW|Z] \stackrel{a.s}{=} W\mathbb{E}[X|Z]$

(ה) **הSMART** $\mathbb{E}[X|Y] = \mathbb{E}[X] - \mathbb{E}[X|Y]$ $\mathbb{E}[X|Y] = \mathbb{E}[X] - \mathbb{E}[X|Y]$ כמעט תמיד

(ו) **טענות מתרגיל 6**

$$i. E[X|Y, g(Y)] = E[X|Y] \quad \text{לכל } g \text{ פונקציה}$$

$$ii. E[E[X|Y, Z]|Y] = E[X|Y]$$

$$Var(X) = E[Var(X|Y)] + Var(E[X|Y]) \text{ iii.}$$

.4 נוסחאת התוחלת השלהמה $\mathbb{E}(X) = \sum_{i=1}^{\infty} \mathbb{E}(X|A_i) P(A_i)$

(א) והמקרה הרציף $f_X(x) = \int_{\Omega} f_{X,Y}(x,y) dy = \int_{\Omega} f_{X|Y}(x,y) f_Y(y) dy = \mathbb{E}(f_{X|Y}(x,Y))$

.5 תוחלת של פונקציה כמשמעותה מקרי $E[Y] = \sum_{x \in \mathbb{R}} f(x)P(X=x)$ במקרה הרציף יהיה אינטגרל!

$$\mathbb{E}\left[\left(\sum_{i=1}^n x_i\right)^2\right] = \sum_{i=1}^n \sum_{j=1}^n \mathbb{E}[x_i \cdot x_j] \text{ .6}$$

טענה 14.1 טריקים על שונות

$$Var(X) = \mathbb{E}((X - \mathbb{E}(X))^2) = \mathbb{E}(X^2) - \mathbb{E}(X)^2 \text{ .1}$$

$$Var(X+a) = Var(X) \text{ .2}$$

$$(\sigma(aX)) = |a|\sigma(X) \text{ וכן } Var(aX) = a^2Var(X) \text{ .3}$$

.4 אם Y מ"מ בעל שונות סופית **בלתי תלוי ב** X אז $Var(X+Y) = Var(X) + Var(Y)$

.5 אם a קבוע אזי $var(a) = 0$

.6 אומד חסר הטיה לשונות $S_n^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right)$

$$var(X) = E(X^2) - [E(X)]^2 \text{ לפי הנוסחה } S_n^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - (\bar{X}_n)^2 \text{ (א)}$$

.7 אם X, Y משתנים מקרים בלתי תלויים אזי

$$Var(XY) = E(X^2)E(Y^2) - E[X]^2E[Y]^2 = E[X]^2Var(Y) + E[Y]^2Var(X) + Var(X)Var(Y)$$

(א) אם יש תלות אזי

$$Var(XY) = E[X^2Y^2] - (E[XY])^2 = cov(X^2, Y^2) + E[X^2]E[Y^2] - (E[XY])^2 = cov(X^2, Y^2) + [var(X) + (E[X])^2][Var(Y) + (E[Y])^2]$$

טענה 15.1 טריקים של Cov

$$Cov(X, Y) = \mathbb{E}((x - \mathbb{E}(X))(y - \mathbb{E}(Y))) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) \text{ .1}$$

.2 אם מ"מ ב"ת אזי $Cov(X, Y) = 0$

$$Cov(X, Y) = Cov(Y, X) \text{ .3}$$

$$Cov(X+Z, Y) = Cov(X, Y) + Cov(Z, Y) \text{ .4}$$

$$Cov(aX, bZ) = abCov(X, Z) \text{ .5}$$

$$Cov(X, X) = Var(X) \text{ .6}$$

$$.7 Var\left(\sum_{n=1}^N X_n\right) = \sum_{n,k \leq N} Cov(X_n, X_k) = \sum_{n \leq N} Var(X_n) + 2 \sum_{n < k \leq N} Cov(X_n, X_k)$$

.8 קורלציה באוכטסיה $\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x}) = cov(x, y)$

.9 $|Cov(X, Y)| \leq \sigma_X \cdot \sigma_Y$ א"ש קושי שורץ!

5.0.1 תכונות בסיסיות של התפוגליות חשובות

טענה 16.1 התפוגליות ביןומיות

.1 ייחי $\{X_i\}_{i \in [N]}$ משתני ברנולי p ב"ת אזי $\sum_{i \in [N]} X_i \sim Bin(N, p)$

.2 חיבור התפוגליות ביןומיות:

.3 $(x+y) \sim bin(N+M, p)$ ב"ת ! אזי $y \sim Bin(M, p)$ וגם $x \sim Bin(N, p)$ אם ו

(א)

$$\sum_{n=1}^{M+N} X_i \stackrel{d}{=} X + Y$$

$$\sqrt{2\pi n} \cdot \left(\frac{n}{e}\right)^n \leq n! \leq e \cdot \left(\frac{n}{e}\right)^n$$

התפלגות פואסון

$$X \sim Po(\lambda)$$

1. אם $(X + Y) \sim Po(\eta + \lambda)$ אז $X \sim Po(\lambda)$ ו $Y \sim Po(\eta)$

2. אם $(Y|X) \sim Bin(X, p)$ אז $Y \sim Po(\lambda p)$ ו $X \sim Po(\lambda)$

התפלגות נורמלית

1. יהיו ל i 2 משתנים נורמליים קרי $X_i \sim N(\mu_i, \sigma_i^2)$ $Y \sim N(\mu_2, \sigma_2^2)$ אז מתקיים כי

$$Y|X \sim N\left(\mu_2 + \underbrace{\frac{Cov(Y, X)}{var(X)}(X - \mu_1)}_{E(Y|X)}, \underbrace{var(Y) - \frac{Cov^2(Y, X)}{var(X)}}_{Var(Y|X)}\right)$$

מסקנה מתרגיל 6 שנובעת המתפלגות דו נורמלית

2. תרגיל 4 שאלה 8 סעיף $ד$

3. המשך התכונות בויקיפדיה !

התפלגות אחידה רציפה

$$1. E[X^n] = \frac{b^{n+1} - a^{n+1}}{(n+1)(b-a)}$$

2. הזרות לינאריות של $U(a, b)$ עדין התפלגו לינארית

$$3. E[X - E(X)]^n = \frac{(b-a)^n (1+(-1)^n)}{2^{n+1}(n+1)}$$

טענה 17.1 וקטור של משתנים מקרים יש לקרוא את הסיכום במופיע ברישומים

טענה 18.1 חווון

יהיו X_1, \dots, X_{2n+1} נאמר שהביטוי הוא חווון אם $\frac{1}{2}$ אם יש כמות אי זוגית המרחב המדגם שלו איזי $Med = X_i$ כלומר באופן פורמלי

$$\text{אם } \{x_i \mid i \in \{1, \dots, 2n+1\}\} \text{ כאשר } Med = X_1 \cdot 1_{\{x_1 \leq x_i\}} + X_2 \cdot 1_{\{x_2 \leq x_i\}} + \dots + X_{2n+1} \cdot 1_{\{x_{2n+1} \leq x_i\}}$$

$$Med = \frac{X_n + X_{n+1}}{2}$$

$$\text{אם } n \text{ נאמר כי } X_1, \dots, X_{2n}$$

מסקנות מתרגיל 4 שאלה 7

טענה 19.1 אי שוויון קושי שוורץ

לכל ζ, η משתנים מקרים מתקיים כי

$$E(\zeta, \eta)^2 \leq E^2(\zeta)E^2(\eta)$$

שיעור 11 אצל שירה

טענה 20.1 טרייק מגניב הסתברות אם יש לי $X_1, X_2 \sim Po(\theta)$ בלתי תלויים איזי

$$E[(\frac{x_1 - x_2}{2})^2] = E[(\frac{x_1 - \theta + \theta - x_2}{2})^2] = \frac{var(x_1) + var(x_2)}{4}$$

יש כאן שימוש 3 טיעונים
 $E(x_1 x_2) = E(x_1)E(x_2)$ כי x_1, x_2 ב"ת
 $var(x_1) = E(x_1 - \theta)^2$
 $cov(x_1, x_2) = E[(x_1 - \theta)(x_2 - \theta)] = 0$ כי x_1, x_2 ב"ת
 משיעור 8 אצל פבל

טענה 21.1 טורי טילול חשובים

$$e^x = \sum_{n=0}^{\infty} \frac{x^n}{n!} . 1$$

$$\sinh(x) = \sum_{n=0}^{\infty} \frac{x^{2n+1}}{(2n+1)!} = \frac{e^x - e^{-x}}{2} .2$$

$$\cosh(x) = \sum_{n=0}^{\infty} \frac{x^{2n}}{(2n)!} = \frac{e^x + e^{-x}}{2} .3$$

$$\ln(1+x) = \sum_{n=1}^{\infty} \frac{(-1)^{n-1}}{n} \cdot x^n .4$$

טענה 22. הגישה הביסטריאנית לפי מיכה

הגישה הביסטריאנית לניתוח מודלים יוצאת מנק הנחה כי הפרמטר בו אני מעוניינים θ הוא משתנה מקרי ואינו ערך קבוע
ambil הינה התיאוריה הביסטריאנית הנתונים נוצרים באופן הבא
הפרמטר הלא ידוע θ הוא תוצאה של ערך שהתקבל של משתנה מקרי בעל התפוגות π
בහינתן הערך θ שהתקבל בשלב הראשון המדגים של תציפות משתנים מקרים בלתי תלויים קרי X_1, \dots, X_n בעל צפיפות $f(x|\theta)$
כלומר סיכום המודל הינו

$$\theta \sim \pi$$

$$X_1, \dots, X_n | \theta \sim F_\theta$$

ההתפלגות π נקראת התפלגות האפראיריות של הפרמטר והוא מכילה את המידע ואת האמונה שלנו על הערכיהם של המשתנה המקרי
לפניהם צופים במדגם.
הגישה הביסטריאנית אומרת כי הסקה על הפרמטר הלא ידוע צריך להיות בעזרת התפלגות האפוסטטריאית
שמוגדרת להיות

$$\pi(\theta | X_1 = x_1, \dots, X_n = x_n) = \pi(\theta) \prod_{i=1}^n \frac{f(x_i | \theta)}{P(X_1 = x_1, \dots, X_n = x_n)}$$

כאשר $P(X_1 = x_1, \dots, X_n = x_n)$ היא ההתפלגות המשותפת של התציפות !
ברישומים של מכנה עמוד 33 בפרק של אמידה
בנוסף חוק ביביס אומר את הדבר הבא $P(B|A) = \frac{P(A \cap B)}{P(B)} = \frac{P(A|B) \cdot P(B)}{P(A)}$ מהסתברות מותנית !

6.0.1 משפט הגבול המרכזי: החוק החלש והחזק של המספרים הגדולים

טענה 23.1 משפט הגבול המרכזי CLT
יהיו x_1, \dots, x_n כך ש $E[x_i] = 1$ ו $var(x_i) = 1$ אז מתקיים כי

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i \xrightarrow{d} N(0, 1)$$

מקורס תורת ההסתברות 1

הגדרה ש skola תחת אותן הנחות $\sqrt{n} \cdot \bar{X} \xrightarrow{d} N(0, 1)$

גרסה משולבת

1. יהיו לי x_1, \dots, x_n עם שונות ותוחלת סופית איזי σ_{x_1} $\sqrt{n} \cdot (\frac{\bar{X} - \mu}{\sigma_{x_1}}) \xrightarrow{i.i.d} N(0, 1)$!! ולא של הממוצע האמפירי !

מתורות ההסתברות 1

למעשה זה הגיוני מהחישוב הזה $\sqrt{n} \cdot \sum_{i=1}^n \frac{x_i - \mu}{\sigma_{x_1}} = \sqrt{n} \cdot \frac{1}{n} \sum_{i=1}^n \frac{x_i - \mu}{\sigma_{x_1}} = \sqrt{n} \cdot (\frac{\bar{X} - \mu}{\sigma_{x_1}}) + \frac{\sigma_{x_1}^2}{n}$
 $(*)$ שונות של ממוצע אמפירי היא

2. יהיו לי x_1, \dots, x_n עם שונות ותוחלת סופית איזי σ_{X_1} $\sqrt{n} \cdot (\bar{X} - \mu) \xrightarrow{d} N(0, \sigma_{X_1}^2)$ משיעור 18

3. שיטת \triangle משפט הגבול המרכזי נשאר נכון תחת הפעלה של פונקציה גזירה ברציפות תהי $H : \mathbb{R} \rightarrow g$ גזירה ברציפות איזי

(א)

$$\sqrt{n}(g(\bar{X}_n) - g(\mu)) \xrightarrow{d} N(0, var(\theta) \cdot [g'(\theta)]^2)$$

$$4. \text{ תהיה } L(X, \theta) = \prod_{i=1}^n f(X_i, \theta) \text{ פונקציה נראות מירבית}$$

$$\text{בנוסף } \infty < \infty \text{ נסיק כי } \hat{\theta} = \arg\max_{\theta} L(X, \theta)$$

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N(0, \frac{1}{I(\theta)}) \text{ משובע 10 פבל !}$$

טענה 24.1 שבוע 8

טענה 25.1 ה חוק המספרים הגדולים The Weak LLN

$$\text{החוק החלש של המספרים הגדולים}$$

$$E|X_i| < \infty \text{ סדרה של משתנים מקרים בלתי תלויים ושווי התפלגות כך } \bar{X}_n \xrightarrow{P} \mu$$

$$\text{יהיו } X_1, \dots, X_n \xrightarrow{i.i.d} F_x$$

$$\bar{X}_n \xrightarrow{L_1} \mu \text{ נסיך כי } \bar{X}_n \xrightarrow{L_2} \mu$$

$$\text{תוך שימוש בהאחה שאם נסיך לתנאי המשפט את הדרישה כי } \infty < E|X_i|^2 \text{ אז } \mu \text{ נסיך כי } \bar{X}_n \xrightarrow{L_q} \mu \text{ נסיך כי } \zeta_n \xrightarrow{L_p} \zeta \text{ אז בהכרח מתקיים כי } \zeta < p \text{ הערכה של פבל !}$$

$$\text{הערה קטנה : מי שwon הדר מאינפי 3 נסיך כי אם } \zeta < p \text{ הערכה של פבל !}$$

$$5. \text{ ה חוק החזק של המספרים הגדולים The Strong LLN}$$

$$E|X_i| < \infty \text{ סדרה של משתנים מקרים בלתי תלויים ושווי התפלגות כך } \bar{X}_n \xrightarrow{a.s} \mu \text{ מוקפdea}$$

7.0.1 פונק יוצרת מומנטים ופונק אופיינית

$$\text{הגדרה 26.1} \text{ פונק יוצרת מומנטים וטענות בסיסיות}$$

$$\text{יהי } X \text{ משתנה מקרי הפונק } M_X(t) = E[e^{tx}] \text{ עבור } t \in (-\delta, \delta) \text{ סביב הראשית}$$

$$M_X(t) = E[e^{tx}] = \sum_{n \in \mathbb{N}} e^{tx} P(X = i)$$

$$\text{עבור המקרה הבודד } M_X(t) = E[e^{tx}] = \int_{-\infty}^{\infty} e^{tx} f_X(x) dx$$

היא פונק יוצרת מומנטים של X השם שלה כי אם גוזרים אותה k פעמים ומיצבים 0 מקבלים את המומנט הא' $E[X^k]$ זה המומנט ה k של המשנה המקרי נשים לב שם המומנט ב k קיים אז בהכרח המומנט $1-k$ קיים !

תכונות בסיסיות

$$1. \text{ אם } S_n = \sum_{i=1}^n a_i X_i \text{ כאשר } X_1, \dots, X_n \text{ משתנים מקרים בלתי תלויים אז}$$

$$2. \text{ יהיו } M_{\alpha X + \beta}(t) = E[e^{(\alpha X + \beta)t}] = e^{\beta t} M_X(\alpha t)$$

$$3. \text{ א' ש } \mathbb{P}(X \geq a) \leq M_X(t) \cdot e^{-ta} \quad a \in \mathbb{R}$$

$$4. \text{ ה Lemma של הופדיינג היה } X \text{ מ' המקיימים } 1 \leq |X| \leq \exp(\frac{t^2}{2}) \text{ עבור } t \in \mathbb{R}$$

$$5. \text{ א' ש הופדיינג היה } \mathbb{P}(X_i \geq a) \leq \exp(-\frac{a^2}{2N}) \text{ עבור } a > 0 \text{ לכל } i \in [N] \text{ אז לכל } 0 < a < 1 \text{ נסיך כי } \mathbb{P}(\sum_{i=1}^n X_i \geq a) \leq \exp(-\frac{a^2}{2N})$$

$$(א) אז מתקיים כי \mathbb{P}(\sum_{i=1}^n X_i \geq a) \leq \exp(-\frac{a^2}{2N})$$

$$6. \text{ למצוא את המומנט ה } k \text{ זה לגוזר } k \text{ פעמים את הפונק יוצרת מומנטים ולהציב 0}$$

$$(א) המוטיבציה לטענה נובעת מטור טילור $M_X(t) = E[e^{tx}] = 1 + tE[X] + \frac{t^2 E[X^2]}{2!} + \dots + \frac{t^n E[X^n]}{n!}$ בשילוב הטענה כי $E[0] = 0$$$

$$7. \text{ אם } 2 \text{ משתנים מקרים } X, Y \text{ מתקיים כי } M_X(t) = M_Y(t) \text{ אז}$$

$$8. \text{ אם } X \text{ הוא וקטור של משתנים מקרים אז } M_X(t) = E[e^{<t, X>}]$$

$$9. \text{ הקשר של פונק יוצרת מומנטים לפונק אופיינית היא כזה } \varphi_X(t) = M_X(it) \text{ כאשר } i \text{ מספר מרוכב}$$

הגדרה 27.1 פונק אופיינית ותכונות בסיסיות של לה

$$\text{לכל משתנה מקרי } X \text{ נגיד } \varphi_X(t) = E[e^{itX}] \text{ עבור } t \in \mathbb{R}$$

$$\text{נשים לב שהביטוי תמיד מוגדר היטב להיות ו } 1 < |\cos(tx) + i\sin(tx)| < 1 \text{ תכונות בסיסיות}$$

$$1. \text{ ל } 2 \text{ משתנים מקרים יש את אותה התפלגות כלו'ם } X_1 = \frac{d}{dt} X_2 \text{ כלו'ם }$$

$$2. \text{ } \varphi_X(0) = 1 \text{ וגם } |\varphi_X(t)| < 1$$

$$3. \text{ המומנטים ה } k \text{ של משתנה מקרי } X \text{ קיימים אז הם מחושבים כך } E[X^k] = i^{-k} \cdot \varphi_X^{(k)}(0) \text{ לגוזר } k \text{ פעמים ולהציב 0 כפול}$$

$$(א) אם $\varphi_X(t) = i^k \varphi_X(0)$ אז כל המומנטים של X קיימים עד k ויקפdea$$

4. אם X_1, \dots, X_n משתנים מקרים ב"ת אזי $\varphi_{a_1 X_1 + \dots + a_n X_n}(t) = \varphi_{X_1}(a_1 t) \cdot \dots \cdot \varphi_{X_n}(a_n t)$

5. אם $a, b \in \mathbb{R}$ עבור $Y = aX + b$ אזי $\varphi_Y(t) = e^{itb} \varphi_X(at)$

6. ויקיפדיה ושיעור 17 פבל

8.0.1 כל האי שוניים החשובים בהסתברות

1. **אי שיוון בול** לכל אוסף של מאורעות מתקיים כי $\mathbb{P}(\bigcup_{k=1}^{\infty} A_k) \leq \sum_{k=1}^{\infty} P(A_k)$
2. **אי שיוון מركוב** יהיו X משתנה מקרי אי שלילי ולכל $a > 0$ מתקיים כי $\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}(X)}{a}$
 - (א) ניסוח שקול $\mathbb{P}(X \geq \mathbb{E}(X)) \leq \frac{1}{a}$
 - (ב) אי שיוון מركוב ההפוך $\mathbb{P}(X \geq \mathbb{E}(X)) \geq 0$
3. **אי שיוון צבישיב** יהיה X בעל שונות סופית אזי לכל $a > 0$ מתקיים כי $\mathbb{P}(|X - \mathbb{E}(X)| \geq a) \leq \frac{\text{Var}(X)}{a^2}$
- (א) לכל X משתנה מקרי בעל שונות סופית וսטיית תקן $X \sigma$ ולכל $b > 0$ מתקיים כי $\mathbb{P}(|X - \mathbb{E}(X)| \geq b\sigma_X) \leq \frac{1}{b^2}$
4. **אי שיוון ינסין** תהיה f פונקציה קמורה כמו (x^2) אם היא מקיימת $f(\alpha a + \beta b) \leq \alpha f(a) + \beta f(b)$ אזי מתקיים כי $E(f(X)) \leq E(f(X))$
 - (א) תהיה f פונקציה קעורה אם היא מקיימת $f(\alpha a + \beta b) \geq \alpha f(a) + \beta f(b)$
5. **הכללה של א"ש מרכוב** לכל X משתנה מקרי בעל תוחלת סופית ומומנט k אזי לכל $a > 0$ מתקיים כי $\mathbb{P}(|X - \mathbb{E}(X)| \geq a) \leq \frac{\mathbb{E}((|X - \mathbb{E}(X)|)^k)}{a^k}$
6. **הכללה של א"ש צבישוב** לכל X מ"מ אי שלילי בעל תוחלת סופית ומומנט מסדר k אזי לכל $a > 0$ מתקיים כי $\mathbb{P}(|X - \mathbb{E}(X)| \geq a) \leq \sqrt[k]{\text{Var}(x)}$
7. יהיו X מ"מ בעל מומנט מעירכי אזי לכל $t > 0$ עבורו $M_X(t) = \mathbb{E}(e^{tx})$ מוגדרת לכל $a \in \mathbb{R}$ ולבסוף $\mathbb{E}(e^{ta}) = \mathbb{E}(e^{tx})$
8. **הлемה של הופציגג** יהא X מ"מ המקיימים $1 \leq |X| \leq t$ אזי לכל $t \in \mathbb{R}$ מתקיים $\mathbb{E}(e^{tX}) \leq \exp(\frac{t^2}{2})$ וכן $0 \leq \mathbb{E}(X) \leq t$
9. **א"ש הופציגג** יהו $\{X_i\}_{i \in [N]}$ משתנים מקרים בלתי תלויים ובעלי תוחלת אפס המקיימים לכל $1 \leq i \leq N$ אזי לכל $a > 0$
 - (א) אזי מתקיים כי $\mathbb{P}(\sum_{i=1}^n X_i \geq a) \leq \exp(-\frac{a^2}{2N})$
10. **אי שיוון קושי שוורץ** לכל ζ, η משתנים מקרים מתקיים כי $|E(\zeta, \eta)|^2 \leq E^2(\zeta)E^2(\eta)$
11. **אי שיוון המשולש בהסתברות** יהיו μ, ζ משתנים מקרים ותהיה $a \in \mathbb{R}$ אזי $P(|\zeta + \mu| \geq a) \leq P(|\zeta| \geq \frac{a}{2}) + p(|\mu| \geq \frac{a}{2})$

2 מודלים סטטיסטיים

הגדה 1.2 מודל סטטיסטי

X data קיימת רשימה של

מניחים שהנתונים הגיעו מהתפלגות כלשהו \mathbb{P}_{θ_0}

H משפחה של התפלגותים שמאימים ש

נרצה לדעת מהי התפלגות האמתית כאשר $X \sim \mathbb{P}_{\theta_0}$

בעיות בסטטיסטיקה

שיעור 2

1. אמידה נקודתית

2. רוחוי סמן

3. בדיקת השערות

הגדה 2.2 מודל פרמטרי ואי פרמטרי

מודל הוא נקרא פרמטרי כאשר $\theta_0 \in H$ נתן לשיכון ב- \mathbb{R}^d כאשר $\infty < d <$ כאשר d הוא מספָא דרגות החופש

מודל נקרא אי פרמטרי אם H נתן לשיכון ב- \mathbb{R}^d כאשר $\infty < d =$ כאשר d הוא מספָא דרגות החופש

למשל כאשר צריך לצירר פונקציה ולהגדיר אותה בכל נק על הישר המשני \mathbb{R}

וזריך לאמוד את f כולה $f \sim X_1 \dots X_n$

הגדה 3.2 מודל ניתן ליזיהו

נאמר כי המודל $\mathbb{P}_{\theta \in \Theta}$ ניתן ליזיהו אם $\theta_1 = \theta_2 \Leftarrow \mathbb{P}_{\theta_1}(x) = \mathbb{P}_{\theta_2}(x) \quad \forall x \in \Omega$

כלומר לכל התפלגות יש θ אחת שמתאימה לה אזי המודל ניתן ליזיהו

באופן שקול אם $\theta_1 \neq \theta_2 \Leftarrow \mathbb{P}_{\theta_1}(A) \neq \mathbb{P}_{\theta_2}(A) \quad \forall A \in \Omega$

שיעור 3

שיעור 2

טענה 4.2 מודל נתון ליזיהו \iff קיים סטטיסטי T כך שהפונקציה $f : \theta \rightarrow \mathbb{E}_\theta(T)$ היא חד חד ערכית

שבוע 2

הוכחה בשבוע 2

שיעור 3

מסקנה מהטענה היא שהמודל נתון ליזיהו אם קיימת f חד חד ערכית

כאשר $f : \theta \rightarrow \text{Var}(T)$

$$T(X) = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \quad \text{ובסטטיסטי } X_1, \dots, X_n \sim N(\mu, \sigma^2)$$

הערה פרקטית: נביט בדוגמה (μ, σ^2) הנל f היא חח' נשים לב שאם מספר המלמים אזי המטריצה המייצגת של מערכת המשוואות תהיה הפיכה קיבל כי במקרה הnl f תלויה במשתנים X_1, \dots, X_n נשים לב שאמם מספר המשוואות = מספר הנעלמים אזי המטריצה המייצגת של מערכת המשוואות תהיה הפיכה קרי f חח' דוגמא בתרגיל CAN

$$ET(X) = \begin{pmatrix} \mu_1 \\ \sigma_1^2 + \mu_1^2 \end{pmatrix} = \begin{pmatrix} \mu_2 \\ \sigma_2^2 + \mu_2^2 \end{pmatrix} \Rightarrow \begin{cases} \mu_1 = \mu_2 \\ \sigma_1^2 + \mu_1^2 = \sigma_2^2 + \mu_2^2 \end{cases}$$

1.0.2 מספיקות ומשפט הפירוק של פישר נוימן

הגדרה 5.2 מספיקות

מושיביצה

על מנת לבצע הסקה על משתנים מקרים לא תמיד נדרש את כל $data$ כדי לבצע הסקה כתע' נציג לצמצם את כמות $data$

יהי T סטטיסטי כלשהו נאמר כי הוא **מספיק**

אם התפלגות המותנית של X תחת $T(X)$ הוא קבוע שלא תלוי ב θ כלומר $(X = a | T(X) = b) \stackrel{\text{ללא תלוי ב } \theta}{\sim} \mathbb{P}_{\theta_0}$

קבועה ביחס ל θ

שבוע 3

שיעור 4

טענה 6.2 שימוש בהגדרת המספיקות

. יהי $X \sim \mathbb{P}_{\theta_0 \in H}$ משתנה מקרי כלשהו

1. נշוב נמצאה סטטיסטי $T(X)$ שהוא **מספיק**

2. נוכח מ X

3. אגדיר משתנה מקרי חדש $X' \sim \mathbb{P}_{\theta_0}(X = s | T(X) = t)$ נשים לב כי X' מותפלג בצורה שלא תלואה ב t

4. מתקיים כי $X' \stackrel{d}{=} X$ איזה מגניב! הערת' $X' \neq X$ אבל יש להם את אותה התפלגות!

5. ככלומר עבור כל הסקה שנרצה לעשותה הערך $T(X)$ הוא כל מה שאנו צריכים מבלי לדעת מהו θ

6. שבוע 3

טענה 7.2 משפט הפירוק של פישר נוימן

תהיה $\mathbb{P}_{\theta \in H}$ מודל סטטיסטי עם פונקציית נראות $L(X, \theta)$ $X \sim \mathbb{P}_{\theta \in H}$ והוא **מספיק** \iff קיימים פונקציות $g(T(X), \theta)$ $h(x)$ כך ש

$$L(X, \theta) = g(T(X), \theta) \cdot h(x) \quad \forall x \in X \quad \theta \in H$$

הערה: נשים לב כי $h(x)$ לא תלוי ב θ זה קריטי!

שבוע 3

הגדרה 8.2 גסות

נאמר כי $T_1(X)$ הוא גס יותר מ($T_2(X)$) אם קיימת פונקציה כך ש

$$\begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$$

אינטואציה: גס יותר הכוונה שהוא מכיל פחות נתונים מאשר $T_2(X)$ או $T_1(X)$

$$\begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$$

כלומר נוכל להגיע מ($T_1(X)$) על ידי מניפולציות אלגבריות

אבל לא נוכל להגיע מ($T_2(X)$) על ידי מניפולציות אלגבריות

נאמר כי $T_1(X)$ ו- $T_2(X)$ הם שקולים אם $T_2(X) \geq T_1(X)$ גס יותר מ($T_1(X)$) ו- $T_2(X)$ גס יותר מ($T_1(X)$)

הערה: אם φ היה חד חד ערכית אז $T_2(X) \geq T_1(X)$ שקולים

מסקנה חשובה אם קיימת f כך ש($T_1(X) = T_2(X) \wedge f(T_1(X)) = f(T_2(X))$) הוא סטטיסטי מספיק איזי ($T_1(X)$) מספיק גם כן!

שבוע 3

מססקנה חשובה מתרגיל 4

אומד נראות מירביה הוא האומד גס יותר מכל סטטיסטי מספיק

$$\hat{\theta} = \underset{\theta}{\operatorname{argmax}} L(X, \theta) = \underset{\theta}{\operatorname{argmax}} [g(T(X), \theta) \cdot h(X)]$$

כאשר T הוא סטטיסטי מספיק כלשהו!

הגדרה 9.2 סטטיטי \min

נאמר כי $T(X)$ הוא סטטיטי \min מספיק אם $(X) \sim T$ גס יותר מכל סטטיטי מספיק אחר שאפשר למצוא .

כלומר $(x) \sim T$ ניתן להגעה אליו על ידי מניפולציות אלגבריות וכל סטטיטיטי

שבוע 3

טענה 10.2 קרייטריוון סטטיטי \min

נכון לשבוע 3 אין לנו קרייטריוון / אלגוריתם למצוא את הסטטיטיטי המספיק \min

אבל אם יש לי T סטטיטי מספיק כלשהו אני יכול להוכיח האם הוא \min או לא

אם T הוא סטטיטי והוא X נקבע ב- $x, y \in X$ נקבע ב- $\frac{L(x, \theta)}{L(y, \theta)}$

אם $x, y \in X$ $T(x) = T(y)$ אז $\frac{L(x, \theta)}{L(y, \theta)}$ קבועה ביחס ל θ כלומר כש θ משתנה מתקיים כי T לכל X !

באופן שקול

אם קיימים $x, y \in X$ כך $\frac{L(x, \theta)}{L(y, \theta)} \neq 1$ לא קבועה ביחס ל θ כלומר כש θ משתנה גם כן !

או T הוא סטטיטי מספיק \min !

הערה פרקטית :

הטענה שקופה יותר קלה הרבה פעמים

זכור שאם הפונקציה היא קבועה אז הנגרת שלה מתאפסת בכל נקודה וזה טענה שימושית

אם מנסים להראות ישרות מהדרה כי $T(x) = T(y)$

שבוע 3

טענה 11.2 סטטיטי \min המסתפיקים להתפליגות שונות

אם $T(X) = \sum_{i=1}^n X_i$ אז $X_1, \dots, X_n \stackrel{i.i.d}{\sim} Po(\lambda)$!

אם $T(X) = (\prod_{j=1}^n X_j, \sum_{j=1}^n X_j)$ אז $X_1, \dots, X_n \stackrel{i.i.d}{\sim} Gamma(\alpha, \beta)$!

אם $\sum_{i=1}^n X_i$ אז $X_1, \dots, X_n \stackrel{i.i.d}{\sim} Ber(\theta)$!

אם $S(X) = (\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2)$ אז $X_1, \dots, X_n \sim N(\mu, \sigma^2)$!

1.2 אלמנטים בתורת החלטות

הגדרה 12.2 setup הוא כזה יש לי $X_1, \dots, X_n \sim P_{\theta \in H}$ כאשר הטעב יודע מהו θ והסטטיטיקאי לא יודע מהו θ והוא בוחר באומדים ל θ $\hat{\theta}_1, \dots, \hat{\theta}_k$

הסטטיטיקאי רוצה לבנות פונקציית הפסד על מנת למזרע נזקים !

הפסד של סטטיטיקאי זה רוחש של הטעב ולהפך יש כאן מעין משחק סכום אפס

לדוגמא ראה שיעור 7 אצל פבל או שבוע 4 דוגמא עם תפוזים !

הגדרה 13.2 פונקציית הפסד רגעי $\theta \rightarrow \mathbb{R} \rightarrow l$

כך $(l(\theta, \theta(X))$ כלומר ערך אחד הוא θ פרמטר לא ידוע

(X) זה האומד ל θ שモבוס על הנתונים X

פונק הפסד נפוצות

אם $\theta \in \mathbb{R}^n$ והוא אומד ל θ

$$l(\theta, \mu) = (||\theta - \mu||_p)^p = [\sqrt[p]{(\theta_i - \mu_i)^p}]^p$$

$$l(\theta, \mu) = Max_i |\theta_i - \mu_i|$$

אותם נורמות שראינו באינפי 3 קרי נורמת p ו Normat ∞ . . . ו Normat ∞

שבוע 4 שיעור 7

הגדרה 14.2 פונקציית סיכון

$R : \Theta \times D \rightarrow \mathbb{R}$

D מרחיב כל האומדים θ

כאשר

$$R(\theta, \theta(X)) = E_\theta l(\theta, \theta(X))$$

כלומר ההפסד הממוצע זו התוחלת של פונק הפסד רגעי

האומד עם פונקציית הסיכון הקטנה ביותר הוא אומד מעולה ! ככלمر אם ($R(\theta, \hat{\theta}(X)) < R(\theta, \tilde{\theta}(X))$) אז $\tilde{\theta}$ נעדיף את $\hat{\theta}$ על פני $\tilde{\theta}$ אצין כי זה סתם סימון ולא מייצג כאן מומוץ !!

שיעור 7 שבוע 4

בהתאם לכך אומרים כי לא ניתן להשוות בין פונקציות סיכון באופן כללי ראה שיעור 8 שבוע 4 דוגמא עם פואסן שלוקטים 2 אומדים קרי אם ($X_1, \dots, X_n \sim Po(\theta)$) $E(X) = \theta$ $Var(\theta) = E(X - \bar{X}_n)^2$ ובית ב 2 האומדים $\hat{\theta}_2 = \frac{1}{n} \sum_{j=1}^n (X_j - \bar{X}_n)^2$ וגם $\hat{\theta}_1 = \bar{X}_n$

הגדרה 15.2 אומד לא כשר

נאמר כי $\hat{\theta}$ הוא אומד לא כשר אם קיים אומד $\hat{\theta}$ כך ש $R(\hat{\theta}, \theta) \leq R(\hat{\theta}_n, \theta)$ לכל $\theta \in H$ וקיים $n \in \mathbb{N}$ כך שאקבל א"ש חריף !

הערות :

פרקטית אם יש לי אומד $(X, \hat{\theta})$ שלא מבוסס על כל התוצאות אני יכול לבנות אומד יותר טוב ממנו כך אם ($R = m.s.e$) $\bar{\theta}(X) = \frac{1}{n} \hat{\theta}(X)$ אז אגדייר

$$R(\bar{\theta}, \theta) = \frac{1}{n^2} var(\hat{\theta}) + \frac{1}{n} E[\hat{\theta}] \leq var(\hat{\theta}) + E[\hat{\theta}] = R(\hat{\theta}, \theta)$$

ומקבל כי מסקנה מהלמה של רואן בלאק וויי

אם ($M(X)$ הוא סטטיסטי מסוים min ביחס ל $\hat{\theta}$) אז $\hat{\theta}(x) = \varphi(M(X))$ לא כשר !

שיעור 4 שבוע 7

הגדרה 16.2 אומד כשר

הוא אומד כשר אם לא קיים אומד $\hat{\theta}$ כך ש $R(\hat{\theta}, \theta) \leq R(\hat{\theta}_n, \theta)$ לכל $\theta \in H$ וקיים $n \in \mathbb{N}$ כך שאקבל א"ש חריף !

שיעור 4 שבוע 7

בהתאם לכך לא ניתן למצוא את האומד האופטימלי

שיעור 4 שבוע 8

טענה 17.2 נניח כי $X \sim N(\theta, 1)$ וабחר $c = \hat{\theta}$ הוא אומד כשר

מסקנה מהטענה היא שכוראות היא לא תכונה טובה במובן הזה שהיא לא יודעת להבדיל בין אומדים טובים לבין אומדים לא טובים

שיעור 4 שבוע 7

2.2 גישות לבחור באומד האופטימלי

שיעור 8 אנו רואים 2 דברים חשובים

1. לא ניתן להשוות בין פונקציות סיכון באופן כללי

2. לא ניתן למצוא את האומד האופטימלי

לכן אנו רוצים לשנות את הצורה חישבה שלנו עד כה ולהציגו על 3 גישות לבחור אומד אופטימלי

1. גישת $minmax$ מינימקס הסטטיסקי הפסימי

$$r(\hat{\theta}) < r(\theta) \quad r(\hat{\theta}) = \sup_{\theta \in H} r(\theta) \quad \text{ונדייר את } \hat{\theta} \text{ על פני } \tilde{\theta} \text{ אם}$$

האומד האופטימי בגישה זו הינו $\hat{\theta}_*$ כך ש $r(\hat{\theta}_*) \leq r(\hat{\theta})$

(א) אמידה בייסאנית (בפרק של אמידה לקרוא מהי בכלל הגישה בייסאנית בסטטיטיקה)

פונק הסיכון לפי יישזה זו הינה $d\theta d\pi(\theta) = \int_H R(\theta, \hat{\theta}) \cdot \pi_1(\hat{\theta}) d\hat{\theta}$

כלומר פונק הסיכון כאן מסתכלת על הסיכום הממוצע של θ

כאשר הסטטיטאי מיניח כי θ_0 נבחר מתוך התפלגות ידועה π_1 למשעה θ_0 הוא משתנה מקרי.

2. הגישות אללו דומות בכך שהם מביאות ערך נומיוני מסוימי ל $\hat{\theta}$.

כלומר ישיחס סדר מלא בגישה זו וכל 2 אומדים הם ברוי השוואת $r(\hat{\theta})$ ו $r(\tilde{\theta})$ הם ברוי השוואת

2. להציגם לאומדים חסרי הטיה

(א) מסתבר שאם אני מצמצם את H שלי לאומדים לחסרי הטיה θ בלבד ניתן למצוא את האומד האופטימלי

חנזור בשיטה ההזו שיש הרבה אומדים טובים שאנו מתעלמים מהם למשל אומד בשיטת נראות מירבית הוא לרוב חסר הטיה .

חומר הטיה משמעותו שהגיאיה של מתפזרת באופן סיטורי באיזוחו מובן.

3. אומדים אוקיוריינטיים

הקדמה :

אמידה בייסאנית (פרק של אמידה לקרים מהי בכלל הגישה בייסאנית בסטטיטיקה) פונק הסיכון לפי גישה זו הינה $r_{\pi_1}(\hat{\theta}) = \int_H R(\theta, \hat{\theta}) \cdot \pi_1(\theta) d\theta$ המוצבcel הינו פונק הסיכון כאן מסתכלת על הסיכום הממוצע של θ כלומר פונק הסיכון מינימלי נבחר מתוך התפלגות ידועה π_1 למעשיה θ_0 הוא משתנה מקרי.

טענה 18.2 למצוא מהו $\hat{\theta}$ שמזער את הפונקציה $r_{\pi_1}(\hat{\theta})$
אנו רוצים לעבור על פני כל $H \in \hat{\theta}$ ולמזער את הפונקציה $r_{\pi_1}(\hat{\theta})$
ונקבל כי

$$\hat{\theta}_\pi(x) \in \operatorname{argmin}_{\theta \in H} \int_H l(\theta, \hat{\theta}) f_{\theta|X}(\theta, x) d\theta$$

שבוע 5 שיעור 9
אמירה כללית כל $(\hat{\theta}) r$: נשים לב שהסיבה שלא יכולתי לגוזר את הביטוי $(\hat{\theta}, \pi)$ r נעוז בעובדה שאין לא יודע איך גוזרים פונקציה אני יודע איך גוזרים פונקציה שהיא סלקר ! ו $\hat{\theta}$ היא לא סלקר !

• **אומד בייס ביחס לפונק הפסד כלשהו הוא תמיד גס יותר מסטטיסטי מספיק** מסקנה מתרגיל 5

טענה 19.2 נשים לב כי $f_{\theta|X}$ הינה

$$f_{\theta|X} = \frac{L(X, \theta) \pi(\theta)}{\int_H L(X, t) \cdot \pi(t) dt}$$

נשים לב שימושזה זו היא בדיק חוק בייס $P(B|A) = \frac{P(A \cap B)}{P(B)} = \frac{P(A|B) \cdot P(B)}{P(A)}$ מחסתברות מותנית !
שבוע 5 שיעור 9
נשים לב שימוש ש $f_x(x)$ לא תלוי ב θ היות וערכנו על כל θ שיש ניתן לכתוב

$$f_{\theta|X} = \frac{L(X, \theta) \pi(\theta)}{\int_H L(X, t) \cdot \pi(t) dt} = C \cdot L(X, \theta) \pi(\theta) = \propto L(X, \theta) \pi(\theta)$$

כאשר C הוא קבוע כלשהו זה נובע מכך ש $f_x(x)$ שהוא המכנה בביטוי לעיל כאשר אני מתנה ב x הוא **מספר קבוע ידוע !**
מסקנות מתרגיל 5

טענה 20.2 אומד בייסני שמזער לפיה שיטת MSE
אם $R(\theta, \mu) = E_\theta(\theta - \mu)^2 = Var_\theta(\theta) + \underbrace{(E_\theta(\theta) - \mu)^2}_{bias}$

אויה האומד בייסני שמזער את $\hat{\theta}$ הינו $r_{\pi_1}(\theta)$
 $\hat{\theta}_{\pi}^*(X) = E(\theta|X) = \operatorname{argmin}_{\theta \in H} [r_{\pi_1}(\theta)] = \operatorname{argmin}_{\theta \in H} [\int_H (\theta - \mu)^2 \cdot f_{\theta|X}(\theta, X) d\theta]$
קרי $E[\theta|X] = \int_{Supp(\theta)} \theta \cdot f_{\theta|X} d\theta = \frac{\int_{Supp(\theta)} \theta \cdot L(\theta, X) \cdot \pi(\theta) d\theta}{\int_{Supp(\theta)} L(\theta, X) \cdot \pi(\theta) d\theta}$
אם מקבשים לחשב מהו

שיעור 9 שבוע 5

טענה 21.2 אומד בייסני שמזער $|E(\theta - \mu)|$

$$\frac{1}{2} = F_{\theta|X}(\mu, X) = \hat{\theta}_\pi(x) = \operatorname{argmin}_{\theta \in H} [\int_H |\theta - \mu| \cdot f_{\theta|X}(\theta, X) d\theta]$$

שיעור 9 שבוע 5

הגדירה 22.2 משפחה של פרוירום קרי π נאמר שהיא צמודה למשפחה (θ, X)

$$\text{אם } \pi \sim f_{\theta|X}$$

כלומר הם מתפלגים באאות הtcpלגות עם פרמטרים שיכולים להיות שונים !

כאשר כעת $\pi, \pi|X$ נקראים צמודי הtcpלגות או צמודי נראות (זה לא קשור לפונקציית נראות)

$$\text{וא נקרא צמוד של } f_{\theta|X}$$

שיעור 9 שבוע 5 יש להסתכל כל הדוגמא !

טענה 23.2 פרופורציה

כשפתרים פרקטית שאלות הרבה פעמים כדאי לשים לב כי $f_{\theta|X}(x) = C \cdot f_g(x)$ כלומר שההtcpלגות הפוסטוריות היא קבוע כפול הtcpלגות מוכרת למשל בינוימית פואסנות וכו. נסמן זאת $f_g(x) \propto f_{\theta|X}$

$$\text{נשים לב שבמקורה מתקיים כי } P(X = \mu) = C \cdot f_g(\mu) \Rightarrow X \sim f_g(\mu, \beta), \alpha \text{ הם פרמטרים כלשהם !}$$

$$\text{דוגמא אם } X \text{ מתפלג בינוימית גם כן עם פרמטרים } (\dots, n, p) \text{ כלשהם לא בהכרח שווים ל } n, p \text{ !}$$

$$\text{Bin}(n, p) = C \cdot \binom{n}{x} p^x (1-p)^{n-x}$$

הטיבה לכך נובעת שאנו יכול לבצע פעולות אלגבריות כלשהם שיכניסו את הקבוע שלי לביטוי מהצורה של הtcpלגות בינוימית

$$\text{והוכחה לכך נובעת מ佗רת החברות אני יכול להגיד קבוצה } G = \{Bin(n, p) | n, 0 \leq p \leq 1 \in \mathbb{R}\} = \text{עם כפל וריגיל}$$

מדובר כאן בחבורה כשהאיבר ניטרלי הוא 1 בנוסח אני מראה כי $c \in \mathbb{R}$ איז $c \in G$ יכול לבטא כל סלקר עם G !

והרי זה הגיוני שההtcpלגות הבינוימית הטווח שלו הוא \mathbb{R}^+ ואז מתקיים כי סלקר כפול כל החבורה אז פרומוטציה של החבורה לנ $G \cdot G = g \cdot G$.

ואז למעשה זה אומר שקיימת סדרה של פעולות אלגבריות שיכניסו לי את הקבוע ! גם אם אני לא יודע להציג על סדרה כזו ספציפית

כעת אני יכול לומר כי X מתפלג $f_g(x)$ כלשהו עם פרמטרים שאני מצאתי ולומר שהפרמטרים הללו נקבעים עד כדי נרמול בקבוע !

כלומר בכתיב רשמי כתובים שמדובר בהtcpלגות כלשהו עד כדי נרמול בקבוע

כאשר מוצאים אומד ביס $f_{\theta|X}(x)$ אנחנו מփשים את האומד min ! שמשמעותו לית את $(x) \pi_r$ כך שams אם אני יודע מהי $|x| \theta$ רק עד כדי נרמול

האומד min שמצויר לי את $(x) \pi_r$ נשאר אותו אומד עד כדי נרמול בקבוע של $|x| \theta$.

כדי למצוא את המרormal שלו אני יכול פשוט לחשוב $1 = \int_C f_{\theta|X} \cdot d\theta$ ולבודד את C והוא המרormal שלו.

2.2.2 אומדים חסרי הטיה

הגדירה 24.2 אומד חסר הטיה

$$\text{נאמר ש } \hat{\theta} \text{ הוא אומד חסר הטיה ל } \theta \text{ אם } E[\hat{\theta}] = \theta - b(\hat{\theta}, \theta) = 0$$

הערה לא מחייבת בדרך אומד חסר הטיה הוא ממוצע אמפירי

שיעור 6 שבוע 10

• הרבה פעמים ניתן לקחת אומדים ולהמיר אותם להיות חסרי הטיה

טענה 25.2 לפי שיטת MSE מתקיים כי $E_{\theta}(\hat{\theta} - \theta)^2 = Var_{\theta}(\hat{\theta}) + b^2(\hat{\theta}, \theta)$ שבוע 6 שיעור 10

הגדירה 26.2 אומד $UMVUE$ הוא אומד חסר הטיה הטוב ביותר

נאמר כי $\hat{\theta}^*$ הוא אומד חסר הטיה ל θ אם $R(\theta, \hat{\theta}^*) = Var_{\theta}(\hat{\theta}^*) \leq Var_{\theta}(\hat{\theta}) = R(\theta, \hat{\theta})$ לכל $H \in H$ ולכל $\hat{\theta}$ אומד כלשהו ל θ !

בנוסף אם קיים אומד שהוא $UMVUE$ אז הוא יחיד עד כדי a.s

כלומר אם T_1, T_2 הם אומדי $UMVUE$ אז מתקיים כי $T_1 \stackrel{a.s}{=} T_2$

שיעור 6

שיעור 11

טענה 27.2 קיימת דוגמא כך שלא קיים לה אומד חסר הטיה

$$\text{אם } ber(\theta) \stackrel{i.i.d}{\sim} X_1, \dots, X_n \text{ נגיד } q(\theta) = \frac{\theta}{1-\theta} \text{ אז לא קיים אומד חסר הטיה ל } q(\theta) !$$

מסקנה למעשיה tcpלגות של X לא משנה כאן מספק שהאומד T יהיה פולינום של θ ממעלה סופית

$$. q(\theta) = \frac{\theta}{1-\theta} = \theta \cdot \sum_{i=1}^{\infty} \theta_i q(\theta)^i \text{ כדי לסתור את הטענה שהוא אומר את } q(\theta) \text{ שהרי } q(\theta) = \frac{\theta}{1-\theta} = \theta \cdot \sum_{i=1}^{\infty} \theta_i q(\theta)^i$$

נשים לב כי אם $T(X_1) = e^{-X} X_1, \dots, X_n \stackrel{i.i.d}{\sim} Exp(\theta)$ אז $E[T(X_1)] = E[e^{-X} X_1]$

כי כאן אני מבצע אינטגרציה בחישוב !

שיעור 6

טענה 28.2 יהי T הוא סטטיסטי שורצחים לאומד את θ התוחלת של X_i

אם אדרוש כי T יהיה חסר הטיה

או זי בהכרח מתקיים

$$\sum_{i=1}^n c_i = 1 \iff T \text{ חסר הטיה} .1$$

$$\bar{X} = min\{Var(T) | \sum_{i=1}^n c_i = 1\} .2$$

טענה 29.2 הلمה של $rao - blackwell$
יהי סטטיסטי מספיך T ואומד ל (θ) עבור q פונקציה ידועה
 $ET^2(X) < \infty$
 $E(T(X))|S(X)$
 נגידר ($)$ אז מתקיים כי

$$E[T^*(X)] = T(X)$$

$$Var(T^*(X), q(\theta)) \leq Var(T(X), q(\theta)) \Rightarrow R(T^*, q(\theta)) \leq R(T, q(\theta))$$

בහbet הפרקטי זה אומר שיש לי כאן מתקכו אך לשפר אומדים!
 יש כאן משחק עם 2 אומדים S, T , שבחירה נבונה שלהם יוצרת לי את האומד $UMVUE$
 את S אניעדיף לבחרו כסטטיסטי מספיך \min !
מסקנות מהלמה

1. אומד שאיןנו גס מסטטיסטי \min מספיך הוא לא כשר לפי $m.s.e$ מזה זה אומר:
 אם אסמן את $M(x)$ הוא סטטיסטי \min מספיך ולא קיימת פונקציה φ כך $\varphi(M(X)) = \varphi(T(x))$ אז $T(x)$ לא כשר ביחס ל $m.s.e$!
2. ניתן לשפר אומדים חסרי הטיה לפि $R - B$?

חזרה על תוחלת מותנית
 נשים לב כי זאת ההגדרה של תוחלת מותנית כמתונה מקרי

$$f(a) = \begin{cases} E[Y|X = a] & P(X = a) > 0 \\ 0 & P(X = a) = 0 \end{cases}$$

כלומר הפלט שלו הוא $E[Y|X = a]$ או והסתכו לפלט הוא $P(X = a)$.

כמובן שבлемה לעיל אני מותעני באיך נראה הפלט שלו שהוא בעצם משתנה מקרי

שיעור 11
 שבוע 6

חסם קרמר ראו ו שימושיו $Cramer - rao$

טענה 30.2 חסם קרמר ראו $Cramer Rao$
מושיבציה

אם התייחס מטבע כמות סופית של פעמים אף פעם אני לא אדע לבדוק מי זה θ ברמת דוק מושלמת
 וכך אני לא אדע לעולם מי זה θ ברמת דוק מושלמת לאacialה למצוא את האומד הטוב ביותר ביחס לפונקציית הסיכון $(\hat{\theta}, R(\theta, \hat{\theta}))$
 לפי שיטת $m.s.e$ קרי $R(\theta, \hat{\theta}) = var(\hat{\theta}) + E(\hat{\theta} - \theta)^2$
 חסם קרמר- מקבל אומד כלשהו ואומר לי עד כמה האומד שלו יכול להיות נמוך!
 למשל אם חסם קרמר מקבל אומד חסר הטיה הוא מוציא לי פלט מהי פונק הסיכון הנמוכה ביותר שאינו יכול לקבל.

ניסוח המשפט

נניח כי המודל הסטטיסטי הוא $(\mathbb{P}_{\theta})_{\theta \in H}$ כאשר H הוא מרחב מפרמטרים ממימד אחד! קרי \mathbb{R}

כאשר x היא פונקציית ציפויות גזירה ב θ כך $x \in \mathbb{R}^n$ ו $\theta \in \mathbb{R}^n$ והוא אנו מניחים כי אינטגרציה וגיאורה הם בריה החלפה כלומה

$$\frac{d}{d\theta} \int_{\mathbb{R}^n} f(x, \theta) dx = \int_{\mathbb{R}^n} \frac{\partial}{\partial \theta} f(x, \theta) dx$$

$$\frac{\partial}{\partial \theta} \int_{\mathbb{R}^n} T(x) f(x, \theta) dx = \int_{\mathbb{R}^n} T(x) \frac{\partial}{\partial \theta} f(x, \theta) dx$$

אזי פונקציית סיכון לפי $m.s.e$ של הסטטיסטי T מקיימת כי

$$R(\theta, \hat{\theta}) = Var_{\theta}(T) + b^2(\theta, T) \geq \frac{(\frac{d}{d\theta} b(\theta, T) + 1)^2}{I_{\bar{X}}(\theta)} + b^2(\theta, T)$$

נשים לב שימושה מכך ש

$$Var_{\theta}(T) \geq \frac{(\frac{d}{d\theta} b(\theta, T) + 1)^2}{I_{\bar{X}}(\theta)}$$

כאשר $b(\theta, T) = E(T) - \theta$ ו x ביטוי זה נקרא אינפורמציה פישר!
 $I_{x_1}(\theta) = E_{\theta}(\frac{\partial}{\partial \theta} \log f(x, \theta))^2$

השווון לעיל לא טריוואלי וההוכחה מופיעה בוקיפידה

נשים לב כי אם יהיה $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} f(x, \theta)$ אז $I_{\bar{X}}(\theta) = n \cdot I_{X_1}(\theta)$

הערות

1. אם T הוא אומד חסר הטיה אזי $R(\theta, T) = Var(T) \geq \frac{1}{I(\theta)}$

2. כאשר מדובר במשתנים בדים אזי נדרש את אותן הנחות כאשר נחליף את $\int_{\mathbb{R}} \sum_{\mathbb{R}}$ ואת פונק הצפיפות בפונק ההסתברות !

3. אם קיבלנו ש T מקיים את כל התנאים הדרושים בשאלת האומד $L(\theta)$ למשל g פונקציה בלשיי נוצרך בחישוב פונק הסיכון $(\hat{\theta}(x), R(\theta, \hat{\theta}(x)))$ להוסיף ולהחסיר את θ באופן מלכוטי כדי להשתמש בחסם $Cramer - rao$ ראה תרגול חזרה של רחל ורגיל 7 שאלה 2

טענה 31.2 שבוע 7

הגדרה 32.2 אומד יiel

נאמר שאומד T הוא יiel אם הוא מקיים את התכונה $UNVUE$
הערות

נשים לב כי בקרוב אומדים חרפי הטיה אומד יiel הוא אומד $UNVUE$

אבל לא להפץ ! אומד $UNVUE$ הוא לא תמיד אומד יiel !!

ראה דוגמא 2.74 בשבוע 7

כאשר יש אפשרות להראות כי $I_{(x=0)} = 1$ הוא אומד $UMUVE$ (בכלים שלא למדן)
אומדים שmaguis ליחס $Cramer Rao$ כולם אומדים שהם $UNVUE$

1. אם $X_1, \dots, X_n \sim Po(\theta)$ אז \bar{X} הוא אומד $UNVUE$ ל θ וקיים

טענה 33.2 טענות בסיסיות על אינפורמציה פישר (θ) I_x ועל ציווילוג $V = \frac{\partial}{\partial \theta} \ln f(X, \theta)$ המגדרת לפיא θ של לוג פונק צפיפות שימוש ישיר של זה
זה נגורת המגדרת לפיא θ של לוג פונק נראות !

1. $E[V] = E[\frac{\partial}{\partial \theta} \ln f(X, \theta)] = 0$

2. יהיו y, x משתנים מקרים בלתי תלויים אזי $I_{(x,y)}(\theta) = I_x(\theta) + I_y(\theta)$ כאשר $I_{(x,y)}(\theta) = I_x(\theta) + I_y(\theta)$

(א) מסקנה יהיה $I_{\bar{X}}(\theta) = n \cdot I_{X_1}(\theta) \sim f(x, \theta)$

3. נניח כי $f(x, \theta)$ גזירה פעמיים וגם ניתן להחליף את האינטגרציה וגזירה קרי $\int_{\mathbb{R}^n} f(x, \theta) dx = \int_{\mathbb{R}^n} \frac{\partial^2}{\partial \theta^2} f(x, \theta) dx$
אז מתקיים כי

$$I(\theta) = -E_{\theta} \frac{\partial}{\partial \theta^2} \log f(x, \theta) = - \int_{\mathbb{R}^n} f(x, \theta) \frac{\partial^2}{\partial \theta^2} \log f(x, \theta) dx$$

$$I(\theta) = E_{\theta} (\frac{\partial}{\partial \theta} \log f(x, \theta))^2 = \int_{\mathbb{R}^n} (\frac{\partial}{\partial \theta} \log f(x, \theta))^2 f(x, \theta) dx .4$$

5. שבוע 7

3.2 התכנסות של משתנים מקרים

הקדמה

בשביל הנושא הזה אנו צריכים להזכיר בסדרות של משתנים מקרים מהתורת ההסתברות
בנוסף בכל הנושא של התכנסות במידה שווה של פונקציות מאינפי 2
שבוע 8

הגדרה 34.2 התכנסות נקודתית של משתנים מקרים

תהיי $\Omega \rightarrow \mathbb{R}$ נאמר שהוא מתכנס נקודתית אם מתקיים $X_n(\omega) \rightarrow X(\omega)$ לכל $\omega \in \Omega$

שיעור 13 זה חומר מאינפי 2

דוגמא לפונקציה שלא מתכנסת נק D
נניח כי $X_n = (1, -1, 1 - 1, \dots, Y_n = \frac{X_n}{n})$ לא מתכנסה בנקודתית כי אם $(1, -2, 3, \dots, 4, \dots)$ אז $X_n \sim N(0, 1)$ ואגיד D סדרה מתכנסת !

הגדרה 35.2 התכנסות במידה שווה של משתנים מקרים

תהיי $\Omega \rightarrow \mathbb{R}$ נאמר שהוא מתכנס במידה שווה אם $\lim_{n \rightarrow \infty} \sup_{x \in I} |f_n(x) - f(x)| \rightarrow 0$

שיעור 13

שבוע 8

טענה 36.2 התכנסות במידה שווה גוררת התכנסות נק

הגדירה 37.2 התכנסות ב- L_p של משתנים מקרים $E(\zeta) < \infty$

עבור $\zeta P \geq 1$ משתנה מקרי עם $\infty < E(\zeta) < \infty$

וגם $E|\zeta_n|^p < \infty$

$$\zeta_n \xrightarrow{L_p} \zeta \text{ אזי נאמר כי } \zeta$$

שיעור 13 שבוע 8

דומגא לפונקציה שלא מתכנסת ב- L_p אם ζ מתפלגת התפלגות קושי איזי ∞ :
 $E(\zeta_n) = \infty$ א"ש שיכולים לעזור להראות התכנסות ב- L_p

1. אי שיוון צביש $\mathbb{P}(|X - \mathbb{E}(X)| \geq a) \leq \frac{\text{Var}(X)}{a^2}$

2. א"ש קושי שורץ ל蹶ה $E(\zeta \cdot \eta)^2 \leq E^2(\zeta)E^2(\eta)$:

3. מי שיוון הלדר מאינפי 3 נסיק כי אם $\zeta \xrightarrow{L_q} \zeta$ איזי בהכרח מתקיים כי $\zeta \xrightarrow{L_p} \zeta$ לכל $q < p$ הערכה של פבל !

הגדירה 38.2 התכנסות בהסתברות

תהיה סדרה של משתנים מקרים ζ_n נאמר שהיא מתכנסת ל- ζ בהסתברות אם

$\varepsilon > 0$

$\zeta_n \xrightarrow{p} \lim_{n \rightarrow \infty} P(|\zeta_n - \zeta| \geq \varepsilon) = 0 \Leftrightarrow \lim_{n \rightarrow \infty} [P(\zeta_n \geq \zeta + \varepsilon) + P(\zeta_n \leq \zeta - \varepsilon)] = 0$ ונסמן ζ מתקיים כי ζ גוררת התכנסות בהסתברות !

ה收敛ות ב- L_p א"ש שיכולים נפוצים לעזור להראות התכנסות בהסתברות :

1. אם ζ_n משתנה מקרי בדיד ניתן לכתוב כי $P(\zeta_n \in \{value \geq 0\}) \leq P(\zeta_n \in \{value \geq 0\})$ ראה תרגיל 8 שאלה 5

2. אי שיוון מרקוב $P(|\zeta_n - \zeta| > \varepsilon) \leq \frac{E(|\zeta_n - \zeta|)}{\varepsilon}$

3. אי שיוון צביש $P(|\zeta_n - E[\zeta_n]| > \varepsilon) \leq \frac{\text{Var}(\zeta_n)}{\varepsilon^2}$

הגדירה 39.2 בערך כל הא"ש של הסתברות !

הגדירה 40.2 התכנסות בהסתפלגות

$P(X_n \leq x) = F(X_n) \xrightarrow{n \rightarrow \infty} F(x) = P(X \leq x)$ נאמר כי $X_n \xrightarrow{d} X$

הגדירה 41.2 שבוע 8

התנאים הבאים שקולים (משפט הארנק בצרפתית)

$\zeta_n \xrightarrow{d} \zeta$.1

לכל g פונקציה רציפה וחסומה $E[g(\zeta_n)] \xrightarrow{n \rightarrow \infty} E[g(\zeta)]$.2

(א) מסקנה אם $\zeta_n \xrightarrow{d} g(\zeta)$ לכל g פונקציה רציפה !

$\varphi_{X_n}(t) = E[e^{it\zeta_n}] \longrightarrow E[e^{it\zeta}] = \varphi_X(t)$.3

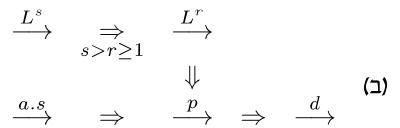
4. שבוע 8

5. שיעור 15 שירה

1.3.2 סדר בראש על כל התכנסויות השונות היחסים ביניהם

1. התכנסות במידה שווה \leftarrow התכנסות נק .

(א) התכנסות במידה שווה \leftarrow התכנסות בהסתברות \leftarrow התכנסות בהסתפלגות .



2. התכנסות בהסתברות וה收敛ות ב- L_p משמרות ארכיטקטורה של גבולות

(א) התכנסות במידה שווה \leftarrow התכנסות ב- L_p \leftarrow התכנסות בהסתברות \leftarrow התכנסות בהסתפלגות .

(ב) לכל מתקיים כי $c \zeta_n \xrightarrow{p} c \zeta$ $c \in \mathbb{R}$

(ג) $\mu \cdot \zeta_n \xrightarrow{p} \mu \cdot \zeta$

3. אם $\zeta_n \xrightarrow{d} g(\zeta)$ ותהי g פונקציה רציפה איזי (ζ) **באופן דומה** אם ζ מותגן ב- L_p $\xrightarrow{p} g(\zeta)$

$$4. \text{ תהא } \zeta \text{ ותהי } \alpha_n \text{ סדרת מספרים כך ש } \alpha_n \rightarrow \infty \text{ אז } \frac{\zeta_n}{\alpha_n} \xrightarrow{d} \zeta$$

$$5. \text{ למת סלוצקי תהא } c \text{ קבוע ומ } \zeta_n \xrightarrow{d} c \text{ כאשר } c \text{ קבוע ו } \mu_n \xrightarrow{d} \zeta + \mu \text{ ו } \mu \text{ משתנה מקרי כלשהו אז מתקאים כי}$$

(א) שימושו לבן קודזה העדינה כאן ברור שיש כאן ארכיטקטורה של גבולות עבור התכונות בהתפלגות אבל כאן יש טענה חזקה יותר שבא $\zeta \xrightarrow{p} \zeta_n$

$$(ב) (\zeta_n, \mu_n) \xrightarrow{d} (c, \mu_n)$$

$$(ג) \zeta_n + \mu_n \xrightarrow{d} \zeta + \mu$$

$$(ד) \zeta_n \mu_n \xrightarrow{d} c \mu$$

$$(ה) \frac{\mu_n}{\zeta_n} \xrightarrow{d} \frac{\mu}{c} \text{ אם } c \neq 0$$

$$6. \text{ נניח כי } c \xrightarrow{d} \zeta \text{ כאשר } c \text{ קבוע ! אז מתקאים כי } c \xrightarrow{p} \zeta$$

$$7. \text{ אם } x_1, \dots, x_n \xrightarrow{a.s} S \iff S_n \xrightarrow{p} S \text{ לפי ויקיפדיה}$$

$$8. \text{ אם } X \xrightarrow{a.s} X_n \text{ וגם } E(Y) < \infty \text{ ו } |X_n| < Y \xrightarrow{a.s} X \text{ לפי ויקיפדיה}$$

9. שבוע 8

10. שיעור 15 שירה

4.2 אמידה במדגים גדולים

כל הסטטיסטיות הקיימים היא אסימפטוטית כי בשביל סטטיסטיות טובות כריך הרבה

$$\text{אנו נדבר על סדרה של תוצאות } X_1, \dots, X_n \xrightarrow{i.i.d} P_{\theta \in H} X_n = X_1, \dots, \hat{\theta}_n(X_{1:n}) \text{ וסדרה של אומדיים}$$

הגדלה 42.2 סדרה עקיבה
נאמר שסדרה היא עקיבה ל- θ אם $\hat{\theta}_n \xrightarrow{p} \theta$ $\iff \lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| > \varepsilon) = 0 \forall \varepsilon > 0$ $\iff \lim_{n \rightarrow 0} P(|\hat{\theta}_n - \theta| > \varepsilon) = 0 \forall \varepsilon > 0$
באופן דומה נאמר שסדרה עקיבה ל- q אם $q(\hat{\theta}_n) \xrightarrow{p} q(\theta)$ אם $q(\theta)$ פונקציה כלשהי

שיעור 16 שירה סוף שבוע 8

שיעור 18

זכור בטענה אם כי $\theta \xrightarrow{d} \zeta$ כאשר θ קבוע אז $\hat{\theta}_n \xrightarrow{p} \zeta$ וכאן בא לידי ביטוי הקשר בין סדרה עקיבה לבין סדרה עקיבה בקצב α_n

הגדלה 43.2 סדרה עקיבה בקצב α_n

תהיה α_n סדרה מונוטונית עולה שאפתה לא סדרה לא מקרית !
ותהיה $\hat{\theta}_n$ סדרה של אומדיים עם התפלגות אסימפטוטית $F(X, \theta)$

נאמר שהסדרה עקיבה בקצב α_n אם $\zeta \sim F(X, \theta)$ $\hat{\theta}_n \xrightarrow{d} \zeta$ כאשר $\alpha_n(\hat{\theta}_n - \theta) \xrightarrow{d} 0$
תחת $\theta \in H$ $\lim_{n \rightarrow \infty} P_{\theta}(|\alpha_n(\hat{\theta}_n - \theta)| \leq x) = F(x, \theta)$
נאמר שהשגיאה של הסדרה הינה $\hat{\theta} - \theta$ והיא שואפת אסימפטוטית בקצב $\frac{1}{\alpha_n}$

דוגמא :

תחת תנאי המשפט הגובל המרוכז $\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N(0, \sigma_{X_1}^2)$
הערה הקצב α_n היא סדרה ייחודית !

מוטיבציה להגדלה : ראיינו כי לפי החוק החזק / חישול המספרים הגדולים מתקיים כי $E(x_i) \xrightarrow{a.s/p} \bar{X} \xrightarrow{a.s/p} E(x_i)$
אבל מסתבר שאתה מסתכל על $\sqrt{n}(\bar{X} - \mu) \xrightarrow{d} N(0, \sigma_{X_1}^2)$. ומכאן בא המוטיבציה להגדיר עקיבה ב- α_n התכונות בהתפלגות !
שיעור 10

טענה עקבות נשמרת תחת הפעלת פונקציה גזירה ברציפות (שייטת \triangle)

תהיה $\hat{\theta}_n$ סדרת אומדיים במובשת על התוצאות x_1, \dots, x_n שאסימפטוטית מתפלגת נורמלית עם שונות של האומד !
נשים לב כי $\hat{V}(\theta)$ זה אומד לשונות של האומד ! ולא השונות של האומד ! קלומר בכל מקום שכתו θ משנה $\hat{V}(\theta)$ בהתאם !
פירושה על $\hat{V}(\theta)$ יכולתי לבחור איזה אומד לשונות של האומד שאינו רוץ ולא כורה היתי צריך לבחור ב- S_n אבל במרקם בהם

הציג את $\hat{\theta} = \theta$ וניתן לתאר את השונות בעוררת $\hat{\theta}$ או אני אຕאר את השונות בעוררת $\hat{\theta}$.

כאשר הסיבה לכך היא ביצועית ! קלומר התכונות היא יותר מהירה !

דוגמא אם $\hat{V}(X_n) = \frac{1}{\lambda} X_n = \frac{1}{\lambda} X_1, \dots, X_n \xrightarrow{i.i.d} Exp(\lambda)$

$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N(0, \hat{V}_{X_1}(\theta))$ (1)
2) תהא $g : H \rightarrow \mathbb{R}$: גזירה ברציפות אזי

$$\sqrt{n}(g(\hat{\theta}_n) - g(\theta)) \xrightarrow{d} N(0, \hat{V}(\theta) \cdot [g'(\theta)]^2)$$

דוגמא :

5.2 רוחי סמך מודוקים ומקורבים

כאן מדובר על אמידה בעזרת רוחי סמך!

הגדרה 44.2 רוחי סמך מודוקים

אינטרול סטטיסטי $I(X) = [a_-(X), a_+(X)]$ הוא רוח סמך בرمת ביטחון הסתברותית $\alpha - 1$
 כלומר $\Theta \in \mathbb{A}$ מתקיים כי $P_\theta(\theta \in I(X)) \geq 1 - \alpha$
 משתמשים בדרכם במשתנה פיבוט שזה משתנה שהתפלגתו לא תליה ב- θ והוא נוצר מ- X_1, \dots, X_n .
 כלומר פונקציה של מרחב המדגש שלו.
 בדרכם לא ניתן לבנות רוח סמך מודוק הינה מספר מקרים שכן אפשר לבנות רוח סמך מודוק!

1. אם $(\sqrt{n} \cdot \frac{|\bar{X}_n - \theta|}{1}) \leq Z_{1-\frac{\alpha}{2}}$ אז ניתן לבנות פיבוט $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} N(\theta, 1)$

2. אם $(\frac{X_1}{\theta}) \sim U(0, 1)$ אז ניתן לבנות פיבוט $X_1, \dots, X_n \sim U(0, \theta)$

רוחי סמך מקורבים

יהי $\hat{\theta}_n$ סדרת אומדים לשאלה ל- θ שمبוססת על המדגמים X_1, \dots, X_n
 כך ש $E(\hat{\theta}_n^2) < \infty$

בנוסף $\theta \xrightarrow{P} \hat{\theta}_n$ סדרה עקביה ל-

כasher אסימפטוטית $\hat{\theta}_n$ מתפלגת נורמלית! עם האומד לשונות של האומד $V(\hat{\theta})$

אז לפי משפט הגבול המרוכז מתקיים כי $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N(0, var(\hat{\theta}))$

על סמך זה נבנה את רוח החסוך $(\sqrt{n} \cdot \frac{-C}{\sqrt{V(\hat{\theta})}} \leq \sqrt{n} \cdot \frac{\hat{\theta} - \theta}{\sqrt{V(\hat{\theta})}} \leq \sqrt{n} \cdot \frac{C}{\sqrt{V(\hat{\theta})}})$
 לכן אסיק כי $P(\hat{\theta} - c \leq \theta \leq \hat{\theta} + c) = \sqrt{n} \cdot \frac{C}{\sqrt{V(\hat{\theta})}}$

$$C = \hat{\theta}_n \pm \frac{1}{\sqrt{n}} \sqrt{\hat{V}(\theta)} \cdot Z_{1-\frac{\alpha}{2}}$$

בדרכם נוהג להשתמש ב- \bar{X}_n ו- $Z_{1-\frac{\alpha}{2}}$ ואז נקבל $\hat{\theta} = \bar{X}_n \pm \frac{1}{\sqrt{n}} \sqrt{\hat{V}(\theta)} \cdot Z_{1-\frac{\alpha}{2}}$

רוחי סמך על פי שיטת Δ

יהי $\hat{\theta}_n$ סדרת אומדים לשאלה ל- θ שمبוססת על המדגמים X_1, \dots, X_n כך ש $\hat{\theta}_n \xrightarrow{P} \theta$

כasher אסימפטוטית $\hat{\theta}_n$ מתפלגת נורמלית! עם האומד לשונות של האומד $\hat{V}(\theta)$

כלומר אם $\sigma^2 = \sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N(0, \sigma^2)$ כאשר σ זה השונות של דגימה בודדת בסדרה $\hat{\theta}_n$:

ותהיי $\Theta \rightarrow \mathbb{R}$: פונקציית גזירה בריציפות לפי שיטת הדلتא מתקיים כי $\sqrt{n}(g(\hat{\theta}) - g(\theta)) \xrightarrow{d} N(0, [g'(\theta)]^2 \cdot V(\theta))$

אם רוחה לבנות רוח סמך $L(g(\theta))$ בرمת מובהקות $\alpha - 1$ נקבל

כעת עשינו רוזקציה לבעה הקודמת!

כלומר נשים לב כי $\sigma^2 = V(\theta) \cdot [g'(\theta)]^2$ וכשנבנה רוח סמך נציב את $\hat{\theta}$ בתוך $g(\hat{\theta})$ σ האומד לשונות של האומד! ואז נבנה את רוח הסמך $N(\hat{\theta}, \sigma^2)$ ובשאם $0 < V(\theta) < L$ וקיים פונקציית גזירה בריציפות כך ש $0 < V(\theta) < L$ וואז רוח סמך $L(\theta)$ בرمת סמך $\alpha - 1$ הינו

$$C = g^{-1}(\hat{\theta}) \pm \frac{1}{\sqrt{n}} \cdot Z_{1-\frac{\alpha}{2}} \cdot L$$

משובע 10 אצל פבל!

יעילות אסימפטוטית רוח סמך לאומד נראות מירבית

מהי סדרת האומדים האופטימלית $\hat{\theta}_n$ זו אני צרכי n הקטן ביותר על מנת להגיע להתפלגות נורמלית!

מסתדר שאומד ביחס לאומד יעיל אסימפטוטית אם $\hat{\theta}_n \xrightarrow{P} \theta$

נאמר ש- $\hat{\theta}^*$ הוא אומד יועל אסימפטוטית אם $E_\theta(\sqrt{n}(\hat{\theta}^* - \theta)^2) = \frac{1}{I_X(\theta)}$

הסבירה לכך נובעת מחומר שלא במסגרת הקורס הזה.

תהיי $L(X, \theta) = \prod_{i=1}^n f(X_i, \theta)$ פונקציית נראות מירבית

בנוסף $\hat{\theta} = argmax_\theta L(X, \theta)$

וזו נקבל כי $\hat{\theta} - \theta \xrightarrow{d} N(0, \frac{1}{I_X(\theta)})$ לכל $\theta \in \Theta$

משובע 10 אצל פבל

יש הנחות נוספות למשפט ש策ריך להתקיים שפבל לא הסביר

טענה 45.2 רוחי סמך מקורבים להתפליגיות מוכרים

1. תהאי $(\bar{X}_n - \sqrt{\frac{1}{n \cdot (\bar{X}_n)^2}} \cdot Z_{1-\frac{\alpha}{2}}, \bar{X}_n + \sqrt{\frac{1}{n \cdot (\bar{X}_n)^2}} \cdot Z_{1-\frac{\alpha}{2}})$ אזי $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} Exp(\lambda)$
2. תהאי $(\bar{X}_n - \sqrt{n[\bar{X}_n(1 - \bar{X}_n)]} \cdot Z_{1-\frac{\alpha}{2}}, \bar{X}_n + \sqrt{n[\bar{X}_n(1 - \bar{X}_n)]} \cdot Z_{1-\frac{\alpha}{2}})$ אזי $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} ber(\theta)$
3. תהאי $(\bar{X}_n - \sqrt{n\bar{X}_n} \cdot Z_{1-\frac{\alpha}{2}}, \bar{X}_n + \sqrt{n\bar{X}_n} \cdot Z_{1-\frac{\alpha}{2}})$ אזי $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} Po(\theta)$
4. תהאי $(\bar{X} - z_{1-\alpha/2}\sigma/\sqrt{n}, \bar{X} + z_{1-\alpha/2}\sigma/\sqrt{n})$ עם σ^2 ידועה רוח סמך למazy $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} N(\mu, \sigma^2)$
5. תהאי $(\bar{X}_n - \frac{S_n}{\sqrt{n}}t_{n-1,1-\alpha/2}, \bar{X}_n + \frac{S_n}{\sqrt{n}}t_{n-1,1-\alpha/2})$ עם שונות לא ידועה אזי $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} N(\mu, \sigma^2)$
6. תהאי $(\frac{(n-1)S_n^2}{\chi_{n-1,\frac{\alpha}{2}}^2}, \frac{(n-1)S_n^2}{\chi_{n-1,1-\frac{\alpha}{2}}^2})$ רוח סמך ל σ^2 אזי $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} N(\mu, \sigma^2)$

6.2 בדיקת השערות

$$X \sim P_{\theta} \in \mathbb{R}^d \text{ כאשר } \theta \in \Theta_0 \oplus \Theta_1 = \Theta \text{ ל } 2 \text{ מרחבים}$$

$H_0 : \theta \in \Theta_0$
 $H_1 : \theta \in \Theta_1$

נדיר מבחן לדחיה השערת ה 0 $\{0, 1\} \rightarrow X \rightarrow \{0, 1\}$ δ כאשר $T(x) \geq C$ נקרא סטטיסטי מבחו ! (פיבוט)

יש קשר בין רוח סמך לבין בדיקת השערות אבל נשים לב שהמטרה שלו בבדיקה השערות היא T יהיה פיבוט בלבד !
ולא בהכרח ש $E(T) = \theta$ למשל עבור λ $X_1, \dots, X_n \sim Exp(\lambda)$ פיבוט טוב כי הוא $\sqrt{n} \cdot \frac{\bar{X} - \frac{1}{\lambda}}{\sqrt{\frac{1}{\lambda^2}}} \sim N(0, 1)$

אבל על מנת לעשות רוח סמך לא אין ברירה ונאלץ לעבור בדרך שיטת ה Δ !

נשים לב שם בניתו רוח סמך סביב θ ברמת סמך של $\alpha - 1$ אם תחת H_0 לא נדחה את השערת 0 אחרת לא נדחה את השערת 0

אם $1 = \delta$ כולם $T(X) \geq C$ נדחה את השערת 0
אם $0 = \delta$ כולם $T(X) < C$ לא נדחה את השערת 0 !
כאשר C הוא מספר קבוע והוא הערך הקרייטי לדוחות את השערת 0 או לא !

עוצמאות וטעויות

טעות מסוג I דוחתי את השערת 0 כאשר היא נכונה !
טעות מסוג II קיבלתי את השערת 0 כאשר היא לא נכונה !
אסתוציאציה בבדיקה השערות האם אדם חולה

טעות מסוג I אמרתי שאדם לא חולה כשבפועל הוא כן חולה (הוא יכול למות בגללי)
טעות מסוג II אמרתי שהוא חולה כשהפועל הוא לא חולה ! (טיפלתי בו סתם)

טעות מסוג I היא החמוריה יותר וממנה אני רוצה להימנע ככל שאפשר ! בדר' נדרוש $P_\theta(T(X) \geq c) \leq 0.05$

נדיר פונקציית עוצמה

Θ $\pi(\theta, \delta) = E_\theta(\delta) = P_\theta(T(X) \geq c)$ $\theta \in \Theta$ (δ היא מכילה בתוכה את החישוב של 2 הטעויות)
 $\pi(\theta_0, \delta) = P_{\theta \in \Theta_0}(T(X) \geq c)$ רמת המובהקות לדוחות את השערת 0
 $\pi(\theta_1, \delta) = P_{\theta \in \Theta_1}(T(X) \geq c)$ עוצמת המבחן לדוחות את השערת 0
 $P_{\theta \in \Theta_0}(T(X) \geq c)$ פונק העוצמה מבטאת טעות מסוג I דוחית H_0 כאשר היא נכונה
 $\underline{\text{עוצמת המבחן}}$

$P_{\theta \in \Theta_1}(T(X) \geq c)$ פונק העוצמה מבטאת טעות מסוג II דוחית H_0 כאשר H_1 נכונה
 $\pi = P_{H_1}(\text{reject } H_0)$ בambilים של מיכה (π זה חישוב עוצמת המבחן)

$\pi(\theta_1, \delta)$ ברוב נשמש ברווחי סמך מקורבים לבדיקת השערות ונקבל C_α
 $P_\theta(T(X) \geq c_\alpha) = 0.05$ קרי $P_\theta(T(X) \geq c_\alpha) = 0.05$ לבנות פיבוט

ו $T(X)$ נרצה שהוא יהיה פיבוט כלומר משטנה שמהה $data$ של התפלגותו לא תלואה ב θ
לרוב נתחיל האומד נקודתי ונפתח אותו לפיבוט המתאים

.1. ומכאן נבנה את הפיבוט המותאים לבדיקת השערות עבור התוחלת.

.2. ומכאן נבנה את הפיבוט המתאים לבדיקת השערות עבור השונות σ^2

.3. נשים לב שהוא לא תמיד המצביע תוק שימוש בלהה של ניצן פירסון מקבלים פיבוטים שונים !

המשתק מה הוא למצוין את c_α בבדיקה השערות !

המן פעמים פרקטית נעשה מחלך כזה $P_{H_0}(T(x) > C) = \alpha \iff P_{H_0}(T(x) \leq C) = 1 - \alpha$

ערך

p-value

$p^{val} = \inf_{t \in \mathbb{R}} P_{H_0}(T(x) \geq t)$ כאשר $t = T(x)$ בambilים אחרים $p^{val} = p(t) = P_{\theta \in \Theta_0}(T(x) \geq t)$

$T(X)$ סטטיסטי תחת H_0

t מה שהתקבל במדגם שלו

הוא

ערך P מוגדר כהתברות לקבל תוצאה זהה לו שהתקבלה מסטטיסטיקת המדגם או תוצאה "קייזונית" ממנה,

תחת ההנחה שהמדגם התקבל מהתפלגות מסוימת, הנחה זו מכונה השערת האפס.

טרם ביצוע המבחן נקבע רמת המבחן (α) או רמת הסמן (H_1) של המבחן, אשר מסומנת באות α .

אם $p^{val} < \alpha$ דוחים את השערת 0

אם $p^{val} > \alpha$ לא דוחים את השערת 0

אם הערך P קטן או שווה ל- α (רמת מובהקות המבחן שנקבעה זה מרמז כי התוצאות שקיבלנו מהמדגם אינן מתאימות עם ההנחה כי השערת האפס היא נכונה ולכן יש לדוחות את אותה השערת).

1.6.2 בדיקת השערות התפלגות מוכנות - מיכה

טענה 46.2 בדיקת השערות עבור התפלגות נורמלית לשונות עברו ($N(\mu, \sigma^2)$) כאשר ההשערה היא $H_1 : \sigma^2 \neq 13$ ו- $H_0 : \sigma^2 = 13$ (היסטוטם דוגמא)

$$P\left(\chi_{n-1, \frac{\alpha}{2}}^2 \leq \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} \leq \chi_{n-1, 1-\frac{\alpha}{2}}^2\right) = P\left(\frac{(n-1)S_n^2}{\chi_{n-1, 1-\frac{\alpha}{2}}^2} \leq \sigma^2 \leq \frac{(n-1)S_n^2}{\chi_{n-1, \frac{\alpha}{2}}^2}\right) = 1 - \alpha$$

משתנה שלא תלוי בשונות ובתוחלת $(n-1)S_n^2 = \sum_{i=1}^n (x_i - \bar{x})^2$

$$\left[\frac{(n-1)S_n^2}{\chi_{n-1, 1-\frac{\alpha}{2}}^2}, \frac{(n-1)S_n^2}{\chi_{n-1, \frac{\alpha}{2}}^2} \right]$$

נדחה את השערת 0 אם σ^2 לא שיך לרווח הסמן

לא נדחה את השערת 0 אם σ^2 שיך למקטע

טענה 47.2 בדיקת לתוחלת עברו התפלגות נורמלית כאשר התוחלת והשונות לא ידועים

$$H_0 : \mu = \mu_0$$

$$H_1 : \mu > \mu_0$$

$$\mathbb{P}_{H_0}(\bar{X} > C) = \mathbb{P}_{H_0}\left(\frac{\bar{X} - \mu_0}{S_n / \sqrt{n}} > \frac{C - \mu_0}{\sigma / \sqrt{n}}\right) = \mathbb{P}_{H_0}(T > \frac{C - \mu_0}{\sigma / \sqrt{n}})$$

כאשר $S_n = \hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})^2$

$$T = \frac{\bar{X} - \mu}{S_n / \sqrt{n}} \sim t_{(n-1)}$$

טענה 48.2 בדיקת השערות על תוחלת בתפלגות נורמלית ושונות ידועה

$$X_1, \dots, X_n \sim N(\mu, \sigma^2)$$

$$H_1 : \mu = \mu_0 \quad H_0 : \mu = \mu_1 * (\mu_1 < \mu_0)$$

$$\mathbb{P}_{H_0}(\bar{X} \stackrel{*}{\leq} C) = \mathbb{P}_{H_0}\left(\frac{|\bar{X} - \mu_0|}{\sigma / \sqrt{n}} < \frac{C - \mu_0}{\sigma / \sqrt{n}}\right) = \Phi\left(\frac{C - \mu_0}{\sigma / \sqrt{n}}\right)$$

$$\text{ואקבל כי } \frac{C - \mu_0}{\sigma / \sqrt{n}} = -z_{1-\alpha}$$

לאחר העברת אגפים נדחה את השערת 0

$$\bar{X} \leq \mu_0 - z_{1-\alpha} \sigma / \sqrt{n}$$

טענה 49.2 קביעת גודל המדגם בקרה של פרופראציית תמייה

$$\mathbb{P}_{H_0}(C_1 \leq F \leq C_2) = 1 - \alpha$$

$$\text{ובזדים מהם } C_2 - C_1$$

$$\text{ומחשבים מהם } Max[\hat{P}(1 - \hat{P})] = 0.5$$

2.6.2 הלמה של נימן פירסון

טענה 50.2 מבין כל המבחנים לבדיקת השערות פשוטות נרצה למבחן מבחן שהוא בעל העוצמה max נניח כי $L(X, \theta)$ קיימת אזי מבחן יחס הנראות הינו

$$T(X) = \frac{L(X, \theta_1)}{L(X, \theta_0)}$$

עם רמת מובהקות α !

נשים לב שהמבחן הוא תמיד חד צדדי !! בלי ערך מוחלט על הסטטיסטי!

שיעור 19 שבוע 11 אצל פבל !

ניסוח שקול :

מבחן UMP לבדיקת השערות פשוטות הוא מבחן יחס נראות מירבית.

בפועל מראים בשיעור 20 ש

מבחן נימן פירסון טוב גם לבדיקת השערות מורכבות ! כלומר הוא מבחן UMP תחת התנאים הבאים :

1. נגידר π זו פונקציית העוצמה היא פונקציה מוגעלה חלש ביחס ל θ !

2. $\delta^*(X)$ קבוע ביחס ל θ

טענה 51.2 אופטימליות בין מבחנים וקצת פילוסופיה

נרצה לענות על השאלה בהינתן 2 מבחנים לבדיקת השערות איזה מבחן נעדיף ?

תחילה נשווה רך בין 2 מבחנים בעלי אותה רמת מובהקות קרי α אחרת לא עשינו בזה כלום !

בהינתן בדיקת השערות לא פשוטה קרי קלומר H_0 יותר גדול מנק בודדת קרי $\Theta \subset \mathbb{R}^d$

נגיד רמת מובהקות בהשערות לא פשוטות בצורה הבאה α . $\sup_{\theta \in \Theta_0} P_{\theta_0}(T(X) \geq C) = \alpha$

יכלנו להגיד בצורה שונה (אופטימליות בייס-לא נלמד).

השוואה בין מבחנים

נאמר שבחן $\delta_1(X)$ הוא עצמי יותר מבבחן $\delta_2(X)$ אם $\pi_{|H_1}(\delta_1(X)) = E_{\theta}(\delta_1(X)) \geq E_{\theta}(\delta_2(X)) \quad \forall \theta \in H_1$
וקיים $\theta \in H_1$ כך שקיימת מבחן אחד יש מצב שהוא יותר! כך שהוא חירף!

לרוב לא יהיה ניתן להשואות בין 2 מבחנים כמו שראינו על פונקציות סיכון אמידה.

UMP

בחן δ^* הוא *UMP*

אם לכל δ מבבחן כלשהו מתקיים כי $\forall \theta \in H_1 \quad E_{\theta}\delta^*(X) \geq E_{\theta}\delta(X)$

כלומר δ^* הוא המבחן עם העוצמה הנגדולה ביותר!

שיעור 20

שבוע 11

3.6.2 בדיקת השערות מורכבות

טענה 52.2 תחת תנאים מסוימים ניתן להלמה של נימן פרסון טובת גם להשערה מורכבת

כפי שאנו רואים בטענה כאן
נניח מודל סטטיסטי H כאשר $\theta \in \Theta$ ויהי δ מבבחן P_{θ_0} כאשר $N - F$ יחס נראות מירביה ברמת מובהקות α

לבידוק השערות פשוטה קרי

$H_0 : \theta = \theta_0$

$H_1 : \theta = \theta_1$

כאשר $\theta_1 > \theta_0$

אם

1. * קבוצה ביחס ל θ_1

2. $\pi(\theta, \delta^*) = E_{\theta}(\delta^*)$

אז * δ הוא מבבחן *UMP* גם לבידוק השערות מהצורה

$H_0 : \theta < \theta_0$

$H_1 : \theta \geq \theta_1$

מתרגול 12 ומשיעור 20

טענה 53.2 מבחן GLRT

יהי * δ מבבחן נראות בעל רמת מובהקות α

מבחן *GLRT* לבידוק השערות מורכבות דוגמא גנרטית לבידוק מבחנים.

לא תמיד ניתן להשתמש בלהמזה שמיון פרסון לבידוק השערות מורכבות

לכן נרצה שתיהיה לנו שיטה גנרטית למציאת מבחנים.

היא לא השיטה הכי טובה שיש אבל יש בא הגון.

נשים לב שהיא מקרה מוכל של נימן פרסון

$$N(X) = \frac{\sup_{\theta \in H_1} L(X, \theta)}{\sup_{\theta \in H_0} L(X, \theta)} \stackrel{*}{=} \frac{L(\hat{\theta}^{(1)}, X)}{L(\hat{\theta}^{(0)}, X)} \stackrel{**}{=} \frac{\sup_{\theta \in H} L(X, \theta)}{\sup_{\theta \in H_0} L(X, \theta)}$$

* כאשר $\hat{\theta}^{(j)} = \operatorname{argmax}_{\theta \in H_j} L(X, \theta)$

** אם פונק $L(X, \theta)$ רציפה. נשים לב כי $\sup_{\theta \in H_0} L(X, \theta)$ מותנה תחת השערת 0 !

או $\delta(X) = 1_{\{N(X) > C\}}$

שיעור 20 שבוע 12

טענה 54.2 מבחן *wild* (המקרה הרוב מימדי) לבידוק השערות מורכבות

$H_0 : \theta \in \Theta_0$

$H_1 \theta \in \Theta_1$

כאשר $\Theta = \Theta_0 \oplus \Theta_1 \subset \mathbb{R}^k$

נניח את H_0 בעררת פונקציה כלשהי R כאשר $H_0 = \{\theta \in H \mid R(\theta) = 0\}$

ונניח כי $\theta \rightarrow L(\theta, X^n)$ מקיימת את התנאים המבטים

וגם $\hat{\theta}$ הינו אומד נראות מרבי כשהוא מקיים $\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N(0, I(\theta)^{-1})$

או מתקיים כי

$$2\log(\hat{\theta}) \xrightarrow{d} \chi_r^2 \quad \forall \theta \in H_0$$

נホג לומר כי סטטיסטי הוא נטול התפלגות אם ההתפלגות שלו לא תלויות ב θ !

מבחן *wild* ווילדס (המקורה החד מימדי)

יהי $\lambda(X) = \frac{\sup_{\theta \in H_1} L(X, \theta)}{\sup_{\theta \in H_0} L(X, \theta)} = \frac{L(\hat{\theta}^{(1)}, X)}{L(\hat{\theta}^{(0)}, X)}$ סטטיסטי GLRT לבדיקה השערות מורכבות קרי
 $H_o : \theta = \theta_0$
 $H_1 : \theta \neq \theta_0$
 כאשר θ_0 הינו נק פנימית באינטראול $\mathbb{R} \subset H \subset H_0$ אזי תחת H_0 מתקיים כי

$$2\log\lambda_n(X) \xrightarrow[n \rightarrow \infty]{d} \chi_1^2$$

מתרגול 12
 שיעור 21 (המקורה הרב מימדי)

3 דוגמאות נגדיות חשובות

טענה 1.3 גם אם המודל אינו ניתן לזהוי זה לא אומר שלא ניתן להעריך את θ !
 דוגמא נבנית במודל הרגרסיה הבא

$$Y_j = \langle x, \beta \rangle + \varepsilon_j \quad j = 1, \dots, n \quad \beta \in \mathbb{R}^p$$

עבור הוקטור המתוקן $\beta \in \mathbb{R}^p$ נשים לב כי ε_j לא ניתן לזהוי עבור β !
 אבל ניתן להעריך את β !
 שבוע 2

טענה 2.3 קיימת דוגמא כך שלא קיים לה אומר חסר הטייה
 אם $q(\theta) = \frac{\theta}{1-\theta}$ נגיד $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} ber(\theta)$ אזי לא קיים אומד חסר הטייה ל(θ)!
 שבוע 6

$$f\left(\begin{matrix} y \\ z \end{matrix}\right) = E[X | \begin{pmatrix} Y \\ Z \end{pmatrix}] = \begin{pmatrix} y \\ z \end{pmatrix} = \sum_{x \in Supp(X)} x \cdot P(X | \begin{pmatrix} Y \\ Z \end{pmatrix}) = \begin{pmatrix} y \\ z \end{pmatrix}) = \sum_{x \in Supp(X)} x \cdot \frac{P(X = x, Y = y, Z = z)}{P[\begin{pmatrix} Y \\ Z \end{pmatrix} = \begin{pmatrix} y \\ z \end{pmatrix}]}$$